Práctica 2.- Programación mixta C-asm x86 Linux

1 Resumen de objetivos

Al finalizar esta práctica, se debería ser capaz de:

- Usar las herramientas `gcc`, `as` y `ld` para compilar código C, ensamblar código ASM, enlazar ambos tipos de código objeto, estudiar el código ensamblador generado por `gcc` con y sin optimizaciones, localizar el código ASM en-línea introducido por el programador, y estudiar el correcto interfaz del mismo con el resto del programa C.
- Reconocer la estructura del código generado por `gcc` según la convención de llamada `cdecl`.
- Reproducir dicha estructura llamando a funciones C desde programa ASM, y recibiendo llamadas desde programa C a subrutinas ASM.
- Escribir fragmentos sencillos de ensamblador en-línea.
- Usar la instrucción CALL (con convención `cdecl`) desde programas ASM para hacer llamadas al sistema operativo (*kernel* Linux, sección 2) y a la librería C (sección 3 del manual).
- Enumerar los registros y algunas instrucciones de los repertorios MMX/SSE de la línea x86.
- Usar con efectividad un depurador como `gdb/ddd`.
- Argumentar la utilidad de los depuradores para ahorrar tiempo de depuración.
- Explicar la convención de llamada `cdecl` para procesadores x86.
- Recordar y practicar en una plataforma de 32bits las operaciones de cálculo de paridad, cálculo de peso Hamming (population count), suma lateral (de bits o de componentes SIMD enteros) y producto de matrices.

2 Convención de llamada `cdecl`

En la práctica anterior ya vimos la conveniencia de dividir el código de un programa entre varias funciones, para facilitar su legibilidad y comprensión, además de su reutilización. En la Figura 1 se vuelve a mostrar la suma de lista de enteros de 32bits, destacando estos tres aspectos que ahora nos interesan:

- La dirección de inicio de la lista y su tamaño se le pasa a la función a través de registros.
- El resultado se devuelve al programa principal a través del registro EAX.
- La subrutina preserva el valor de EDX.

Probablemente el autor de esta función considere que quien reutilice sus funciones debe aprender qué registros se deben usar para pasar los argumentos, teniendo garantizado que a la vuelta de la subrutina sólo se habrá modificado el valor del registro EAX, que contiene el valor de retorno de la función.

Se pueden usar varias alternativas para pasar parámetros a funciones y para retornar los resultados de la función al código que la ha llamado. Se llama ***convención de llamada*** (*calling convention*) al conjunto de alternativas escogidas (para pasar parámetros y devolver resultados). Corresponde a la convención determinar, por ejemplo:

- Dónde se ponen los parámetros (en registros, en la pila o en ambos).
- El orden en que se pasan los parámetros a la función.
  - Si es en registros, en cuál se pasa el parámetro 1º, 2º, etc.
  - Si es en pila, los parámetros pueden introducirse en el orden en que aparecen en la declaración de la función (como en Pascal) o al contrario (como se hace en C).
    - La primera opción exige que el lenguaje sea fuertemente tipificado, y así una función sólo podrá tener un número fijo de argumentos de tipo conocido.
    - La segunda opción permite un nº variable de argumentos de tipos variables.
- Qué registros preserva el código de llamada (invocante) y cuáles la función (código invocado).
  - Los primeros (*caller-save, salva-invocante*) pueden usarse directamente en la función.
  - Los segundos (*callee-save, salva-invocado*) deberían salvarse a pila antes de que la función los modifique, para poder restaurar su valor antes de retornar al invocante.

- Quién libera el espacio reservado en la pila para el paso de parámetros: el código de llamada (invocante, como en C) o la función (código invocado, como en Pascal).
    - La primera opción permite un número variable de argumentos. El invocante siempre sabe cuántos han sido esta vez (en cada invocación podría ser un número distinto).
    - La segunda opción exige que el lenguaje sea fuertemente tipificado, pero ahorra código: la instrucción para liberar pila aparecen una única vez, en la propia función.

La convención de llamada depende de la arquitectura, del lenguaje, y del compilador concreto. Así en un procesador con pocos registros, como los x86 de 32 bits, generalmente se prefiere pasar los parámetros a una función a través de la pila, mientras que en procesadores con muchos registros se prefiere pasar los parámetros a través de registros. En los procesadores x86_64 se usan registros y la pila.

En este guión nos centraremos en la convención `cdecl`, estándar para arquitecturas x86 de 32 bits en lenguaje C, y también en lenguaje C++ para funciones globales. Si programamos funciones ensamblador respetando la convención `cdecl`, el código objeto generado (usando `as`) podrá inter-operar con código objeto generado (mediante `gcc`) a partir de código fuente C/C++; es decir, podremos construir un programa mezclando ficheros objeto compilados desde fuentes C/C++ con ficheros objeto ensamblados desde fuentes ASM. La convención de llamada `cdecl` tiene las siguientes especificaciones:

```
# suma.s:     Sumar los elementos de una lista
#             llamando a función, pasando argumentos mediante registros
# retorna:    código retorno 0, comprobar suma en %eax mediante gdb/ddd

# SECCIÓN DE DATOS (.data, variables globales inicializadas)
.section .data
lista:
       .int 1,2,10, 1,2,0b10, 1,2,0x10
longlista:
       .int   (.-lista)/4
resultado:
       .int   -1

# SECCIÓN DE CÓDIGO (.text, instrucciones máquina)
.section .text
_start: .global _start           # PROGRAMA PRINCIPAL

       mov     $lista, %ebx      # 1er arg. EBX: dirección array lista
       mov  longlista, %ecx      # 2º  arg. ECX: número elementos a sumar
       call suma                 # llamar suma(&lista, longlista);
       mov  %eax, resultado

       mov  $1, %eax             #   void _exit(int status);
       mov  $0, %ebx
       int  $0x80

# SUBRUTINA: int suma(int* lista, int longlista);
# entrada:   1) %ebx = dirección inicio array
#            2) %ecx = número de elementos a sumar
# salida:       %eax = resultado de la suma

suma:
       push    %edx              # preservar %edx
       mov  $0, %eax             # acumulador
       mov  $0, %edx             # índice
bucle:
       add  (%ebx,%edx,4), %eax
       inc        %edx
       cmp   %edx,%ecx
       jne    bucle

       pop   %edx                # restaurar %edx
       ret
```

Figura 1: suma.s: paso de parámetros por registros

- Los parámetros se pasan en pila, de derecha a izquierda; es decir, primero se pasa el último parámetro, después el penúltimo… y por fin el primero.
- El espacio reservado en la pila para el paso de parámetros lo libera el código que llama. Estas dos primeras alternativas de la convención permiten al lenguaje C soportar funciones con un número variable de argumentos.
- El resultado se devuelve en EAX usualmente (ver Tabla 1). También se pueden pasar punteros o referencias a una función C/C++ para que ésta modifique el valor referenciado.
- Los registros EAX, ECX, EDX son *salva-invocante* (*caller-save*): la función los puede usar directamente, sin tener que preservarlos (sin tener que guardarlos en la pila ni recuperarlos antes de retornar). Es responsabilidad del invocante (*caller*, el código que llama a la función) guardarlos en la pila si desea recuperar su valor tras el retorno de la función.
- Los registros EBX, ESI y EDI son *salva-invocado* (*callee-save*): la función debe preservarlos (guardarlos en pila) y restaurarlos antes de retornar, si necesitara modificar su contenido.
- Los registros ESP y EBP son especiales y no deben manipularse: la convención `cdecl` asume que funcionan como puntero de pila y marco de pila.

Tipo de variable	Registro
[unsigned] long long int (64-bit)	EDX:EAX
[unsigned] long	EAX
[unsigned] int	EAX
[unsigned] short	AX
[unsigned] char	AL
punteros	EAX
float / double	ST(0) – tope de pila x87

Tabla 1: Devolución de resultados de una función bajo cdecl - 32 bits

Hay algunas variaciones en la convención `cdecl` según el sistema operativo y compilador de C/C++, aunque no afectan a lo comentado hasta ahora (más información en [3]).

Ejercicio 1: suma_01_S_cdecl

Modificar el fichero suma.s mostrado anteriormente (Figura 1) para volverlo conforme a la convención `cdecl`. Ensamblar, enlazar, depurar, y comprobar que sigue calculando el resultado correcto. En la Figura 2 se muestran las líneas que deben modificarse.

```
# suma.s del Guión 1
# 1.- añadiéndole convención cdecl
#      as --32 -g      suma_01_S_cdecl.s -o suma_01_S_cdecl.o
#      ld -m elf_i386  suma_01_S_cdecl.o -o suma_01_S_cdecl
...
_start: .global _start     # PROGRAMA PRINCIPAL

       pushl  longlista    # 2º  arg: número de elementos a sumar
       pushl     $lista    # 1er arg: dirección del array lista
       call   suma         # llamar suma(&lista, longlista);
       add    $8, %esp     # quitar args
       mov  %eax, resultado
...
# SUBRUTINA: int suma(int* lista, int longlista);
suma:
       push %ebp           # Ajuste marco pila
       mov  %esp, %ebp
                           # antes, en el original, conservar todo
       push %ebx           # push %edx
       mov  8(%ebp), %ebx  # ahora %ebx es callee-save en cdecl
       mov 12(%ebp), %ecx  # %ecx,%edx no (caller-save)
...

       pop %ebx            # Recuperar callee-save
       pop %ebp            # Deshacer marco pila
       ret
```

Figura 2: suma_01_S_cdecl.s: paso de parámetros por pila (convención cdecl)

Observar que, en el *programa principal*, se introducen los argumentos en pila en orden inverso, se invoca a la función, y tras el retorno se limpia la pila. En la *función*, se empieza ajustando el marco de pila, se preservan registros salva-invocado (si hace falta), y se accede a los argumentos tomando como base el marco de pila EBP. Al retornar, se restauran los registros preservados y el marco de pila anterior.

Toda función comienza ajustando el marco de pila al tope actual de pila (salvando previamente el marco anterior), de manera que durante la ejecución de la función, `(%ebp)` es el antiguo marco, `4(%ebp)` es la dirección de retorno, y a partir de `8(%ebp)` están los argumentos de la función. Las dos primeras instrucciones de cualquier función `cdecl` son las mostradas en la Figura 2. El que genera el código (ya sea programador humano o el gcc) sabe qué registros modifica la función, así que si alguno de ellos es salva-invocado debe preservar su valor (en pila) para poder restaurarlo a la vuelta. En nuestro caso necesitamos 4 registros, así que al menos uno debe ser salva-invocado. Toda función termina dejando la pila como estaba: restaurando los registros salva-invocado, el marco de pila anterior, y la dirección de retorno, esto es, retornando al invocante.

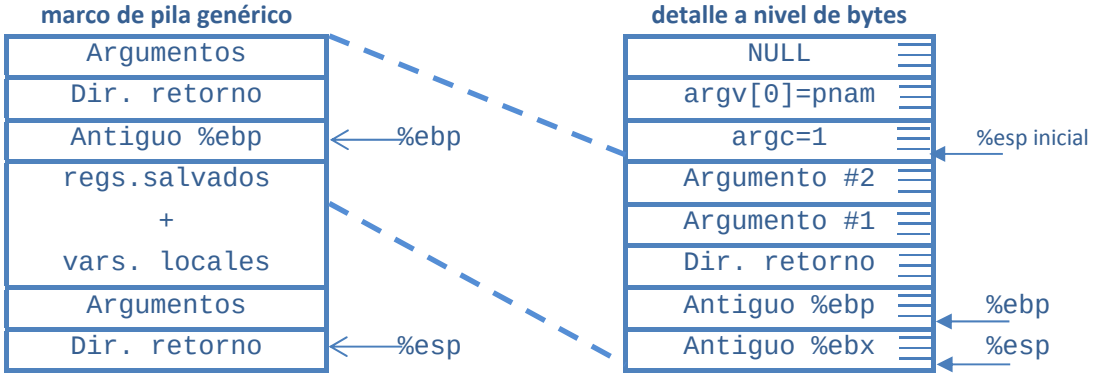

Figura 3: marco de pila genérico, y marco correspondiente al ejemplo

Ejecutar paso a paso con ddd el programa suma_01_S_cdecl de la Figura 2 y comprobar que todo sucede como se ha indicado. En el Apéndice 1 se ofrecen unas preguntas de autocomprobación para comprobar la correcta comprensión de este ejercicio.

Ejercicio 2: suma_02_S_libC

La ventaja de usar la convención `cdecl` es que podemos inter-operar con otras funciones conformes a `cdecl`, como son obviamente todas las funciones de la librería C. En la sección 2 del manual se documentan los *wrappers* a llamadas al sistema (p.ej.: `man 2 exit`), y en la sección 3 las funciones de librería (p.ej.: `man 3 printf`).

Modificar el programa anterior, añadiéndole una llamada a `printf()` para sacar por pantalla el resultado en decimal y hexadecimal, y sustituyendo la llamada directa al *kernel* Linux por el correspondiente *wrapper* libC. Ensamblar, enlazar, depurar, y comprobar que sigue calculando el resultado correcto. En la Figura 4 se muestran las líneas que deben modificarse, y aparece como comentario el comando utilizado para enlazar con la librería C.

```
# suma.s del Guión 1
# 1.- añadiéndole convención cdecl
# 2.- añadiéndole printf() y cambiando syscall por exit()
#      as --32 -g      suma_02_S_libC.s -o suma_02_S_libC.o
#      ld -m elf_i386  suma_02_S_libC.o -o suma_02_S_libC \
#            -lc   -dynamic-linker /lib/ld-linux.so.2

.section .data
lista:       .int 1,2,10,  1,2,0b10,  1,2,0x10
longlista:   .int (.-lista)/4
resultado:   .int -1
formato:     .ascii "resultado = %d = %0x hex\n"
                        # formato para printf() libC
.section .text
_start: .global _start          # PROGRAMA PRINCIPAL
```

```
        pushl longlista
        pushl    $lista
        call  suma
        add   $8, %esp             # quitar args
        mov   %eax, resultado      # resultado=suma(&lista, longlista)

        push %eax              # versión libC de syscall __NR_write
        push %eax              # ventaja: printf() con formato "%d" / "%x"
        push $formato          #      traduce resultado a ASCII decimal/hex
        call  printf           # == printf(formato,resultado,resultado)
        add  $12, %esp
                               # versión libC de syscall __NR_exit
        pushl $0               #      mov $1, %eax
        call exit              #      mov $0, %ebx
#       add $4, %esp  (no ret)#      int $0x80     ==  _exit(0)
...
```

Figura 4: suma_02_S_libC.s: llamando a libC desde ASM

Observar que, para cada llamada a función, el *programa principal* introduce los argumentos en pila en orden inverso, y tras el retorno se limpia la pila. En la Figura 5 se ilustra la situación de la pila antes de llamar a cada función. Notar que no habrá oportunidad de limpiar los argumentos de `exit()`.

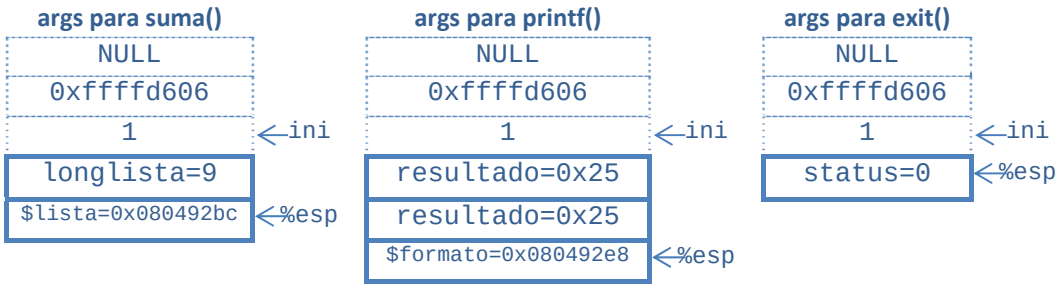

Figura 5: paso de argumentos correspondientes al ejemplo libC

Como se usan dos funciones de la librería C, es necesario enlazar con dicha librería (*switch* `-lc`). Si no se hace, las funciones `printf()/exit()` no se pueden resolver, es decir, el enlazador no sabe a qué dirección de subrutina saltar. Además, una instalación normal de gcc espera que las aplicaciones se compilen para usar la librería C dinámica (`libc.so`, por *shared object*), por lo cual necesitaremos especificar el enlazador dinámico a usar (el de 32bits, en nuestro caso).

Ejecutar desde línea de comandos el programa suma_02_S_libC de la Figura 4, aprovechando que ahora imprime el resultado por pantalla. Depurarlo también paso a paso con ddd, comprobando que se producen las configuraciones de pila mostradas en la Figura 5. En el Apéndice 1 se ofrecen unas preguntas de autocomprobación para comprobar la correcta comprensión de este ejercicio.

Ejercicio 3: suma_03_SC

La ventaja de usar la convención `cdecl` es que podemos inter-operar con otras funciones conformes a `cdecl`. Hemos probado con funciones de la librería C, y ahora experimentaremos con nuestra propia función `suma()`, pasándola a lenguaje C.

Modificar el programa anterior, eliminando el código ensamblador de `suma()` y creando un nuevo módulo en lenguaje C que realice la misma función. Ensamblar, enlazar, depurar, y comprobar que sigue calculando el resultado correcto. En la Figura 6 se muestran las líneas que deben modificarse, y los comandos utilizados para compilar, ensamblar y enlazar los dos módulos.

```
# MODULO suma_03_SC_s.s
# suma.s del Guión 1
# 1.- añadiéndole convención cdecl
# 2.- añadiéndole printf() y cambiando syscall por exit()
# 3.- extrayendo suma a módulo C para linkar
#      gcc -m32 -O1 -g -c suma_03_SC_c.c
#      as --32      -g    suma_03_SC_s.s -o suma_03_SC_s.o
#      ld -m elf_i386     suma_03_SC_c.o    suma_03_SC_s.o -o suma_03_SC \
#             -lc   -dynamic-linker /lib/ld-linux.so.2
```

```
...
formato:      .ascii "resultado = %d = %0x hex\n\0"
                              # formato para printf() libC (asciiz)
...
```

```
# MODULO suma_03_SC_c.c
int suma(int* array, int len)
{
    int  i,   res=0;
    for (i=0; i<len; i++)
        res += array[i];
    return res;
}
```

Figura 6: Aplicación suma_03_SC: llamando a módulo C desde módulo ASM

En este ejercicio se ha usado sufijo _SC_ para indicar que se llama desde ASM a C, y los módulos repiten en su nombre la extensión (`_s.s`, `_c.c`) para que no coincidan los nombres de los ficheros objeto. Recordar que `gcc -c` reutiliza el nombre del fuente, y que con `as` hay que indicar el nombre del objeto.

Ejecutar desde línea de comandos el programa resultante, comprobando que imprime el mismo resultado por pantalla. Depurarlo también paso a paso con ddd, comprobando que al pasar a lenguaje C los argumentos formales adquieren el valor de los parámetros actuales pasados en pila. Probablemente necesitemos listar la subrutina `_start` desde línea de comandos gdb, ya que al enlazar hemos puesto el objeto C como primer módulo, y por tanto ése será el que muestre ddd al inicio. En el Apéndice 1 se ofrecen las preguntas de autocomprobación para comprobar la correcta comprensión de este ejercicio.

Ejercicio 4: suma_04_SC

Antes de llevárnoslo todo a lenguaje C, vamos a probar a dejar únicamente los datos y el punto de entrada en ensamblador. Nuestra única instrucción va a ser un salto (no llamada) a la subrutina `suma`, y ésta accederá a los datos globalmente, imprimirá el resultado y terminará el programa. No retornaremos de suma, ni usaremos instrucciones ensamblador para pasarle parámetros. Los cambios necesarios se ilustran en la Figura 7. No hay cambios en las instrucciones para compilar, ensamblar y enlazar los dos módulos. Hacerlo, y comprobar que se sigue calculando el resultado correcto.

```
# MODULO suma_04_SC_s.s
# suma.s del Guión 1
# 1.- añadiéndole convención cdecl
# 2.- añadiéndole printf() y cambiando syscall por exit()
# 3.- extrayendo suma a módulo C para linkar
# 4.- dejando sólo los datos, que el resto lo haga suma() en módulo C
...
.global lista, longlista, resultado, formato
.section .text
_start:  .global _start
       jmp suma
```

```
# MODULO suma_04_SC_c.c
#include <stdio.h>  // para printf()
#include <stdlib.h> // para exit()

extern int lista[];
extern int longlista, resultado;
extern char formato[];

void suma()
{
    int  i,   res=0;
    for (i=0; i<longlista; i++)
        res += lista[i];
    resultado = res;

    printf(formato,res,res);
    exit(0);
}
```

Figura 7: Aplicación suma_04_SC: dejando sólo datos y punto de entrada en módulo ASM

Notar que en el módulo C se añaden los `includes` necesarios, cambia la signatura de la función `suma` (ni toma argumentos ni produce resultado), y se usan los nombres de las variables globales, no de los parámetros. También se imprime el resultado y se finaliza el programa.

En el módulo ASM se declaran globales los símbolos exportados. En el módulo C se declaran externos. A `gcc` le basta con saber el tipo de esas variables, para generar las instrucciones que acceden a ellas (salvo la dirección, que se deja a cero, sin rellenar). En tiempo de enlace se resuelven estos símbolos: por el nombre se localiza la definición en las tablas de símbolos y se descubre la dirección que ocupan.

Ejecutar desde línea de comandos el programa resultante, comprobando que imprime el mismo resultado por pantalla. Depurarlo también paso a paso con ddd, comprobando que el salto a lenguaje C no toca la pila, y que una vez en C las variables globales son exactamente las definidas en ASM. Probablemente necesitemos listar la subrutina `_start` desde línea de comandos gdb, debido al orden de enlace escogido. En el Apéndice 1 se ofrecen las habituales preguntas de autocomprobación.

Ejercicio 5: suma_05_C

Pasar todo el código a lenguaje C. Comprobar que se sigue calculando el resultado correcto.

```c
# MODULO suma_05_C.c
#include <stdio.h>  // para printf()
#include <stdlib.h> // para exit()

int lista[]={1,2,10,  1,2,0b10,  1,2,0x10};
int longlista= sizeof(lista)/sizeof(int);
int resultado=-1;

int suma(int* array, int len)
{
    int  i,   res=0;
    for (i=0; i<len; i++)
        res += array[i];
    return res;
}

int main()
{
    resultado = suma(lista, longlista);
    printf("resultado = %d = %0x hex\n",
           resultado,resultado);
    exit(0);
}
```

Figura 8: suma_05_C: código C puro

Notar que se deshace el cambio de signatura de la función `suma`, las variables globales se definen en C, y el programa principal llama a nuestra función y a las de librería. El punto de entrada es ahora `main`. Notar la sintaxis para declarar e inicializar arrays, si se desconocía. El operador `sizeof` resulta útil para reproducir los cálculos que hacíamos en el fuente ASM.

Ejecutar desde línea de comandos el programa resultante, comprobando que imprime el mismo resultado por pantalla. Depurarlo con ddd. En el Apéndice 1 se ofrecen las habituales preguntas de autocomprobación.

Ejercicio 6: suma_06_CS

Volver a pasar la función `suma` a un módulo ensamblador separado. En la Figura 9 se ilustra cómo quedaría el módulo C, y se recuerdan las instrucciones para compilar, ensamblar y enlazar (varias alternativas posibles). Comprobar que se sigue calculando el resultado correcto.

Las distintas alternativas para obtener el ejecutable son un recordatorio de lo estudiado en la Práctica 1 sobre compilación, ensamblado y enlazado. Como tenemos un módulo C y otro ASM, podemos:

1. compilarlo todo desde `gcc` (es la opción preferible), ó
2. compilar (`gcc`) y ensamblar (`as`) los fuentes a objetos, y enlazarlos con `gcc`, ó
3. enlazar esos mismos objetos con `ld`.

```c
# MODULO suma_06_CS_c.c
#include <stdio.h>  // para printf()
#include <stdlib.h> // para exit()
extern int suma(int* array, int len);

int lista[]={1,2,10,  1,2,0b10,  1,2,0x10};
int longlista= sizeof(lista)/sizeof(int);
int resultado=-1;

int main()
{
    resultado = suma(lista, longlista);
    printf("resultado = %d = %0x hex\n",
           resultado,resultado);
    exit(0);
}
```

```
# MODULO suma_06_SC_s.s
# ...
# 5.- entero en C
# 6.- volviendo a sacar la suma a ensamblador
#      gcc -m32 -O1 -g    suma_06_CS_c.c    suma_06_CS_s.s -o suma_06_CS
#
#      gcc -m32 -O1 -g -c suma_06_CS_c.c
#      as  --32     -g    suma_06_CS_s.s -o suma_06_CS_s.o
#      gcc -m32           suma_06_CS_c.o    suma_06_CS_s.o -o suma_06_CS
#
#      LDIR=`gcc -print-file-name=`
#      ld -m elf_i386     suma_06_CS_c.o    suma_06_CS_s.o -o suma_06_CS  \
#          -dynamic-linker /lib/ld-linux.so.2                             \
#          /usr/lib32/crt1.o /usr/lib32/crti.o /usr/lib32/crtn.o          \
#          $LDIR/32/crtbegin.o   $LDIR/32/crtend.o        -lc
...
```

Figura 9: suma_06_CS: programa C llamando a función asm cdecl

Notar que se indica que `suma` es `extern`, como antes lo fueron `lista` y `longlista`. Es tan frecuente que las funciones estén en otro módulo, que no hace falta indicar `extern` al compilador, basta con mostrarle el prototipo. Incluso si no se indicara prototipo, el compilador asumiría que la función es `int func()` (que devolverá int), produciéndose un aviso si resultara tener argumentos o devolver otra cosa. Los prototipos de una librería suelen recolectarse en un fichero `<librería>.h`, para su inclusión en programas que utilicen la librería.

Notar que es preferible compilar, ensamblar y enlazar la aplicación con gcc, ya que el punto de entrada es `main` (y vamos a usar la librería C). Anteriormente hemos preferido usar `as` porque el punto de entrada era `_start`, teniendo que enlazar explícitamente con la librería C y el enlazador dinámico cuando hemos usado funciones libC. El compilador gcc añade esas opciones (y otras para soporte en tiempo de ejecución), admite ficheros fuente C y ASM en una sola línea de comandos, y puede compilar, ensamblar y enlazar en un solo comando, por lo cual es preferible en el caso actual. Sólo para demostrar que pueden seguir usándose `as` y `ld`, se ofrecen las instrucciones alternativas. Notar que en este caso, hace falta también indicar explícitamente el soporte en tiempo de ejecución (*C runtime*).

Ejecutar desde línea de comandos el programa resultante, comprobando que imprime el mismo resultado por pantalla. Depurarlo con ddd, comprobando que el marco de pila generado para `suma` es idéntico a cuando la función estaba programada en lenguaje C.

3 Ensamblador en-línea (*inline assembly*) con `asm()`

Hay ocasiones especiales en que resultaría conveniente introducir unas pocas instrucciones de lenguaje ensamblador entre (*en-línea con*) el código C, por motivos muy concretos:

- Utilizar alguna instrucción de lenguaje máquina que el compilador no conozca, o no utilice nunca, o no use en el caso concreto que nos interesa (`rdtsc`, `xchg`, etc)

- Aprovechar alguna característica (registro, etc) de la arquitectura que el compilador no utilice (*timestamp counter*, *performance counters*, etc).
- Conseguir alguna optimización que no sea posible mediante *switches* u otras características del compilador (*builtins*, etc), del lenguaje (*keywords* como *register*, etc), o mediante librerías optimizadas.

En general es difícil, a menudo muy difícil, y siempre muy tedioso, intentar ganar a gcc o cualquier compilador optimizador en lo que se refiere a movimientos de datos, bucles y estructuras de control, que usualmente es un gran porcentaje del texto de cualquier programa. Resulta más productivo estudiar el manual del compilador y usar los *switches* correspondientes (p.ej.: `-mtune=core2`, `-msse4.2`) para que éste genere instrucciones específicas de la arquitectura (si decide que son ventajosas), y reordene y alinee instrucciones y datos teniendo en cuenta detalles de la microarquitectura ignorados u obviados por la mayoría de los programadores (y aún prestándoles atención, se necesitarían manuales y simuladores para aprovecharlos en igual grado que gcc).

Por otro lado, puede suceder que sólo deseemos utilizar unas pocas instrucciones *entre medias* de nuestro código C para intentar mejorar sus prestaciones (por alguno de los motivos citados anteriormente). Para posibilitar esa inserción de unas pocas instrucciones ensamblador *en-línea* con el código C, gcc también dispone (igual que otros compiladores) de una sentencia `asm()`, con la siguiente sintaxis:

- Básica: `asm("<sentencia ensamblador>")`
- Extendida: `asm("<sentencia asm>":<salidas>:<entradas>:<sobrescritos>)`

Aunque en principio el mecanismo está pensado para una única instrucción ensamblador, se puede aprovechar la concatenación de strings (dos strings seguidos en un fuente C se concatenan automáticamente) y los caracteres "\n\t" como terminación, para insertar varias líneas que el ensamblador interprete posteriormente como instrucciones distintas de código fuente ASM.

Si el código *inline* es totalmente independiente del código C, en el sentido de no necesitar coordinación con objetos controlados por el compilador (variables, registros de la CPU, etc), puede usar la sintaxis básica (sin *restricciones*). Pero habitualmente, desearemos que el código *inline* se coordine con el código C, porque queramos modificar el valor de alguna variable (***restricciones*** de <salida>), o consultarlo (***restricciones*** de <entrada>), o simplemente para no interferir con las optimizaciones en curso (***restricciones*** <sobrescritos>). En ese caso, usaremos la sintaxis extendida (con restricciones).

Ejercicio 7: suma_07_Casm

Una ventaja de usar ensamblador *inline* es que podemos incorporar lo que de otra forma se hubiera convertido en un pequeño módulo ASM en el propio código C, facilitando el estudio de la aplicación y evitando la necesidad de ensamblar y enlazar separadamente, o al menos reduciendo el número de ficheros fuente implicados.

Modificar el ejemplo anterior, volviendo a incorporar el código ensamblador de suma como ensamblador en-línea. Compilar, ejecutar, y comprobar que sigue calculando el resultado correcto. En la Figura 10 se muestra el fuente resultante.

```
#include <stdio.h>  // para printf()
#include <stdlib.h> // para exit()

int lista[]={1,2,10,  1,2,0b10,  1,2,0x10};
int longlista= sizeof(lista)/sizeof(int);
int resultado=-1;

int suma(int* array, int len)
{
//  int  i,   res=0;             // cuando gcc compila este código C
//  for (i=0; i<len; i++)        //   produce un código ASM
//      res += array[i];         //   similar al incorporado más abajo
//  return res;                  //   mediante la sentencia asm()
```

```
    asm("push      %ebx    \n"    // clobber (sobrescritos):
"      mov  8(%ebp),%ebx   \n"    // EBX
"      mov 12(%ebp), %ecx  \n"    // ECX
"                          \n"
"      mov $0, %eax        \n"    // EAX
"      mov $0, %edx        \n"    // EDX
"bucle:                    \n"
"      add (%ebx,%edx,4), %eax\n"
"      inc       %edx      \n"
"      cmp  %edx,%ecx      \n"
"      jne bucle           \n"
"                          \n"
"      pop  %ebx           \n"    // La sintaxis extendida incluiría:
//   :                             // output
//   :                             // input
//   : "cc",                       // clobber
//     "eax","ebx","ecx","edx"     // en este caso, la hemos comentado
    );
}

int main()
{
    resultado = suma(lista, longlista);
    printf("resultado = %d = %0x hex\n",
           resultado,resultado);
    exit(0);
}
```

Figura 10: suma_07_Casm: incorporando módulo ASM como inline-asm

Se ha escogido el nombre `_Casm_` para indicar que se usa asm *inline*. Notar que, como conocemos la convención `cdecl`, podemos obtener los valores de los argumentos `array` y `len` sin necesidad de coordinarnos con gcc mediante *restricciones* de entrada, y producir el valor de retorno (en EAX) sin indicar *restricciones* de salida. Ni siquiera necesitamos avisar a gcc de los registros que alteramos (restricciones de sobreescritos, o *clobber constraints*). El registro "cc" son los flags de estado (*condition codes*). A veces puede ser necesario indicar a gcc que nuestro código *inline* modifica los flags.

En el Apéndice 1 se ofrecen las habituales preguntas de autocomprobación.

Restricciones de salida, de entrada, y sobrescritos

Como ya se comentó, es difícil ganar a gcc en movimiento de datos o control de flujo, y tedioso el simple hecho de intentarlo. El ensamblador en-línea es más efectivo para las situaciones en que conocemos alguna funcionalidad o mejora que gcc ha pasado por alto. Usualmente se trataría de insertar una única instrucción ensamblador (o pocas), pero que necesitamos coordinar con gcc porque:

- Modifican alguna variable (restricciones de salida)
- Necesitan el valor de alguna variable, constante, dirección… (restricciones de entrada)
- Modifican estado de la CPU que pueda estar usando gcc (restricciones sobrescritos)

Esa coordinación se expresa mediante las denominadas *restricciones* (*constraints*), con esta sintaxis:

- Salidas: [<nombre ASM >] "=<restricción>" (<nombre C >)
- Entradas: [<nombre ASM >] "<restricción>" (<expresión C >)
- Sobrescritos: "<reg>" | "cc" | "memory"

La idea general de funcionamiento de las restricciones es como sigue: antes de entrar a ejecutar la sentencia `asm()`, gcc satisface las condiciones de entrada, copiando cada <expresión C> a un recurso ensamblador (registro, inmediato, memoria, ver Tabla 2) que cumpla la restricción indicada (por eso se llaman *restricciones* de entrada). Durante la ejecución de la sentencia `asm()`, nos podremos referir al recurso mediante el <nombre ASM> escogido. Después de ejecutar la sentencia `asm()`, gcc satisface las condiciones de salida, copiando los recursos <nombre ASM> que lleven "=<restricción>" de salida a la variable <nombre C > que se indique.

Por poner un ejemplo para fijar conceptos, se podría escribir **`[arr] "r" (array)`** en restricciones de entrada para indicar a gcc que lo que en C llamamos **`array`** (su dirección de inicio) se debe almacenar en un registro cualquiera (restricción **`"r"`**, ver Tabla 2) antes de entrar en la sentencia `asm()`, y como no sabemos en cuál registro decidirá almacenarlo, vamos a llamarlo **`%arr`** en el código ensamblador.

Mediante estas copias, gcc asocia (*coordina*) el nombre o expresión C con algún recurso ensamblador (registro de la CPU, registro del coprocesador, operando inmediato, operando de memoria) que cumpla la restricción indicada. En la Tabla 2 se resumen las restricciones más comúnmente usadas.

El nombre ensamblador es opcional. Si se indica en la restricción, podremos hacer referencia a dicho recurso en nuestro código *inline* como %[<nombre ASM>]. Si no, el recurso se referenciará como %0, %1, %2… en el orden en que aparezca en la lista de restricciones, empezando con las restricciones de salida y terminando con las de entrada.

Notar que las restricciones de salida deben llevar el modificador "=" (o también "+" para entrada y salida, ver Tabla 2). Como son de salida, no se puede indicar una <expresión C> cualquiera, tiene que ser un <nombre C> de una variable (*L-value*) que pueda almacenar el valor del recurso al acabar la sentencia `asm()`.

En el apartado de sobrescritos se deben indicar los recursos que modifica nuestro código *inline*, a fin de que gcc no optimice erróneamente el acceso a los mismos, ignorando que han sido alterados en nuestra sentencia `asm`. En general, es buena idea comprobar el código ensamblador generado alrededor de nuestra sentencia `asm`, para anticipar (si lo vemos antes) o corregir (si no lo hemos visto antes) un posible error de coordinación con gcc, debido a haber especificado unas restricciones incorrectas. Conviene recordar que el mecanismo `asm` fue pensado inicialmente para una única instrucción máquina, y así veremos que a veces una restricción "=r" (salida registro) reutiliza el mismo registro que una entrada "r". A menudo, usando la restricción "+r" (o "=&r") desaparece el problema (*¿por qué?*).

El manual de gcc [7] y su *Inline assembly HOWTO* [8] son los documentos de referencia para las distintas restricciones disponibles, tanto en general para todos los procesadores soportados, como en particular para los procesadores de las familias x86 y x86-64. Existen también numerosos tutoriales y documentos web (ver por ejemplo la *Linux Assembly HOWTO* [9] y los tutoriales *SourceForge* [10]) sobre esta temática. Para nuestros objetivos, seguramente nos baste conocer las restricciones más básicas:

Restricción	Registro	Restricción	Operando
a	EAX	**m**	**operando de memoria**
b	EBX	q	registros eax, ebx, ecx, edx
c	ECX	**r**	**registros eax, ebx, ecx, edx, esi, edi**
d	EDX	g	registro (q) o memoria (m)
S	ESI	I	valor inmediato 0..31 (despl-rotación)
D	EDI	**i**	**valor inmediato entero**
A	EDX:EAX	G	valor inmediato punto flotante
f	ST(i) – registro p.flotante	<n>	en restricción de entrada, un número indica que el operando también es de salida, la salida número %<n>
t	ST(0) – tope de pila x87		
u	ST(1) – siguiente al tope		
Modificadores			
=	**Salida (write-only)**	=&	Early-clobber (salida sobrescrita antes de leer todas las entradas)
+	**Entrada-Salida**		

Tabla 2: Restricciones (constraints) y modificadores más utilizados

La mayoría de los fragmentos *inline* pueden resolverse con las restricciones que hemos retintado.

Ejercicio 8: suma_08_Casm

Modificar el ejemplo anterior, reduciendo el código ensamblador en-línea al cuerpo del bucle `for`. Compilar, ejecutar, y comprobar que sigue calculando el resultado correcto. En la Figura 11 se muestra el fragmento relevante.

```c
int suma(int* array, int len)
{
    int  i,   res=0;
    for (i=0; i<len; i++)
//      res += array[i];          // traducir sólo esta línea a ASM
    asm("add (%[a],%[i],4),%[r]"
     : [r] "+r" (res)           // output-input
     : [i]  "r" (i),            // input
       [a]  "r" (array)
//   : "cc"                     // clobber
    );
    return res;
}
```

Figura 11: suma_08_Casm: inline-asm con restricciones

Notar que para redactar este código *inline* no es necesario conocer la convención `cdecl`, y podemos obtener referencias a `array`, `i` y `res` coordinándonos con `gcc` mediante restricciones de salida y entrada.

El efecto de "**`res+=array[i];`**" se puede conseguir con una única sentencia ASM del estilo "**`add (%ebx,%edx,4),%eax`**" con tal de que en EBX esté la dirección del **`array`**, en EDX el índice **i** (ambos de entrada) y EAX se corresponda con la variable **res** (entrada-salida, ya que acumulamos sobre dicha variable). De hecho, nos daría igual que fueran esos u otros registros. Por eso ponemos restricción "r" en lugar de algo más concreto que tal vez podría interferir en las optimizaciones que esté realizando gcc alrededor de este código. En el Apéndice 1 se ofrecen las habituales preguntas de autocomprobación.

Ejercicio 9: suma_09_Casm

Como el código generado es el mismo, no se espera que haya ninguna diferencia en cuanto a prestaciones entre los últimos tres ejemplos.

Para comprobarlo, crear un programa que incorpore las tres alternativas de `suma`, y que ejecute cada una cronometrando su tiempo de ejecución, usando la función de librería C `gettimeofday`. Compilar, ejecutar, comprobar que las tres versiones producen el mismo resultado, y calcular el tiempo de ejecución promedio (de cada versión) sobre 10 ejecuciones consecutivas. En la Figura 12 se muestra el programa sugerido.

```c
#include <stdio.h>          // para printf()
#include <stdlib.h>         // para exit()
#include <sys/time.h>       // para gettimeofday(), struct timeval

#define SIZE (1<<16)        // tamaño suficiente para tiempo apreciable
int lista[SIZE];
int resultado=0;

int suma1(int* array, int len)
{
    int  i,   res=0;
    for (i=0; i<len; i++)
        res += array[i];
    return res;
}

int suma2(int* array, int len)
{
    int  i,   res=0;
    for (i=0; i<len; i++)
//      res += array[i];
    asm("add (%[a],%[i],4),%[r]"
     : [r] "+r" (res)       // output-input
     : [i]  "r" (i),        // input
       [a]  "r" (array)
//   : "cc"                 // clobber
    );
    return res;
}

int suma3(int* array, int len)
{
```

```
    asm("mov 8(%%ebp), %%ebx          \n"     // array
"       mov  12(%%ebp), %%ecx         \n"     // len
"                                     \n"
"       mov $0, %%eax                 \n"     // retval
"       mov $0, %%edx                 \n"     // index
"bucle:                               \n"
"       add (%%ebx,%%edx,4), %eax     \n"
"       inc        %%edx              \n"
"       cmp  %%edx,%%ecx              \n"
"       jne bucle                     \n"
     :                                        // output
     :                                        // input
     : "ebx"                                  // clobber
    );
}

void crono(int (*func)(), char* msg){
    struct timeval tv1,tv2;                   // gettimeofday() secs-usecs
    long           tv_usecs;                  // y sus cuentas

    gettimeofday(&tv1,NULL);
    resultado = func(lista, SIZE);
    gettimeofday(&tv2,NULL);

    tv_usecs=(tv2.tv_sec -tv1.tv_sec )*1E6+
             (tv2.tv_usec-tv1.tv_usec);
    printf("resultado = %d\t", resultado);
    printf("%s:%9ld us\n", msg, tv_usecs);
}

int main()
{
    int i;                                    // inicializar array
    for (i=0; i<SIZE; i++)                    // se queda en cache
        lista[i]=i;

    crono(suma1, "suma1 (en lenguaje C    )");
    crono(suma2, "suma2 (1 instrucción asm)");
    crono(suma3, "suma3 (bloque asm entero)");
    printf("N*(N+1)/2 = %d\n", (SIZE-1)*(SIZE/2)); /*OF*/

    exit(0);
}
```

Figura 12: suma_09_Casm: esqueleto de programa para comparar tiempos de ejecución

Notar que se ha definido un tamaño de array lo suficientemente grande como para que el tiempo de ejecución sea apreciable. De hecho, el motivo para no poner un tamaño mayor ha sido la incomodidad para calcular el resultado correcto mediante la fórmula correspondiente. En cualquier caso, incluso para tamaños mucho menores se venía cumpliendo que el tiempo de ejecución crecía linealmente con el tamaño del array (tamaño doble→tiempo doble), lo cual indica, para un algoritmo de complejidad lineal como éste, que el tiempo cronometrado no está dominado por otros factores ajenos, sino por el propio proceso realizado (sumar los N elementos, en este caso).

Notar que el tamaño del array no supone perjuicio para el cronometraje de ninguna versión. En nuestro caso es lo suficientemente pequeño como para caber en cache L2 y estar disponible para las tres ejecuciones, una vez inicializado el array. Si fuera demasiado grande tampoco importaría, porque al no caber, igual no cabe al inicializar, que no cabe al cronometrar la versión 1, que no cabe al cronometrar ninguna otra. En este caso, el orden de ejecución de las versiones no afecta a su cronometraje. Tampoco afecta cuál sea la primera que se ejecute, tras inicializar el array. En general, ese no es el caso, y se debe meditar cuidadosamente cómo realizar la medición de forma justa y equitativa para todas las versiones.

Notar que se ha introducido una ligera variante en la versión 3, y que cuando hay lista de sobrescritos, los registros se referencian como %%<reg>. Cuando no hay sobrescritos, basta con %<reg>. En el Apéndice 1 se ofrecen las habituales preguntas de autocomprobación.

Este mismo programa nos puede servir de esqueleto para el resto de trabajos de optimización y medición de tiempos (cronometraje) contemplados en esta práctica.

4 Trabajo a realizar

Nos interesaría experimentar con ejemplos que permitan obtener ventaja sobre `gcc`, y que al mismo tiempo sean lo suficientemente sencillos como para estudiarlos y programarlos en pocas sesiones de prácticas. O aún mejor, que no requieran estudio adicional.

Estas condiciones las cumplen por ejemplo: el cálculo del peso Hamming o *"population count"*, ya visto en clase de teoría, para el cual existe una instrucción SSE4.2 cuyo uso `gcc` no podrá deducir a partir de nuestro código C; y el cálculo de la paridad, que también se postula en el libro de teoría (p.300) como buen candidato para ello, siendo esta vez el bit PF la característica que `gcc` no aprovecha; en ambos casos daremos pistas sobre las instrucciones a utilizar, la idea general que debe implementar del tramo de código ASM, y las restricciones a utilizar, al objeto de guiar, orientar y acelerar tanto la lectura del manual del repertorio de instrucciones como la programación de los tramos `asm( )`.

Se trata por tanto de programar varias versiones de estas dos funciones:

- Sumar los pesos Hamming (nº de bits activados) de todos los elementos de un array
- Sumar las paridades de todos los elementos de un array

…con y sin ensamblador en-línea, y comprobando siempre la corrección del resultado calculado. Para ello, podemos consensuar algunos ejemplos pequeños de prueba, cuyo resultado correcto pueda calcularse a mano. Pero para que el tiempo de medición sea apreciable tendremos que usar arrays de mayor tamaño, y para conocer el resultado correcto hará falta una fórmula aplicable a los datos de entrada utilizados.

Se deben cronometrar de forma justa y equitativa todas las versiones. Una vez desarrollado el programa y comprobados los ejemplos de tamaño pequeño, repetiremos 10 veces la ejecución para promediar los tiempos de ejecución de cada versión, y repetiremos el estudio para distintos niveles de optimización. Los tiempos promediados se pueden presentar en una gráfica de paquete ofimático (Calc o Excel).

Se propondrá comenzar con un programa normal en C (la versión más inmediata posible), y continuar con mejoras que no requieran ASM, si las hubiera. Cuando no se pueda mejorar más en lenguaje C, pasar a ASM en-línea. A veces también propondremos versión ASM de versiones C no óptimas, como ejercicio preparatorio, especialmente si la versión óptima ASM se basa en SSE4.

En el laboratorio disponemos de procesadores con SSE3 (no SSE4), mientras que muchos estudiantes disponen de portátiles con SSE4. Se pedirá por tanto realizar alguna versión ASM que se pueda probar en el laboratorio, y se dejará sugerida alguna otra que aproveche las capacidades superiores de los portátiles, para los entusiastas que siempre quieren probar lo más avanzado.

Según la temporización de cada curso, se procurarán realizar guiadamente (como Seminario Práctico) los Ejercicios 1-6 aproximadamente (incluso 7-9 si sobrara tiempo). Aunque no diera tiempo a tanto, responder a las preguntas de autocomprobación, comprender los programas mostrados y ejercitarse en el uso de las herramientas son competencias que cada uno debe conseguir personalmente.

Para aprender el funcionamiento de nuevas instrucciones (sean o no del repertorio SSE) basta con leer el manual de Intel y probarlas en la propia sentencia ASM *inline* (y depurarlas con ddd, si no produjeran el resultado esperado).

Al objeto de facilitar el desarrollo progresivo de la práctica, se sugiere realizar en orden las siguientes tareas:

4.1 Repasar los apuntes de clase

Esta práctica es posterior o simultánea al estudio en clase de teoría de diversos conceptos relevantes [1], como por ejemplo: marcos de pila (Tema 2.1, transparencias 31-39), códigos de condición (Tema 2.2, tr. 18-25), bucles (tr. 37-49), estructura de la pila (Tema 2.3, tr. 1-32), convenciones de llamada (tr. 33-36), punteros y variables locales (tr. 45-48), declaración y acceso a arrays (Tema 2.4, tr. 15-37). Se recomienda su estudio detallado.

4.2 Contestar las preguntas de autocomprobación (suma_01-suma_09)

El objetivo es comprender con detalle el proceso de ensamblado, compilación y enlace de los programas mixtos C-ASM, utilizar con soltura las herramientas implicadas (incluyendo `objdump` y `nm`), entender cuándo y por qué hace falta enlazar la librería C, el *runtime* C y el enlazador dinámico, entender cuándo conviene usar `as/ld` y cuándo `gcc`, comprender la convención `cdecl`, ser capaz de leer (comprender) y redactar código ASM en convención `cdecl` y en-línea (*inline* ASM), y adquirir habilidad en el manejo de las herramientas usadas (compilador, ensamblador, enlazador y depurador).

4.3 Calcular la suma de bits de una lista de enteros sin signo

Utilizar el programa `suma_09` de la Figura 12 como esqueleto para cronometrar diversas versiones de una función que sume los bits (peso Hamming, *popcount*) de los elementos de una lista de N números. Notar que la suma puede llegar a ser 32*N (en modo 32bits, donde un entero ocupa 4B), si todos valieran 2^{32}-1 (y por consiguiente tuvieran activados todos los bits). Concluir que basta calcular la suma en un entero, para cualquier valor práctico de N. ¿Cómo de grande puede ser N en dicho peor caso?

Para tener alguna posibilidad de detectar errores en nuestro código, lo comprobaremos con algunos ejemplos sencillos como los siguientes:

- `unsigned lista[SIZE]={0x80000000, 0x00100000, 0x00000800, 0x00000001};`
- `unsigned lista[SIZE]={0x7fffffff, 0xffefffff, 0xfffff7ff, 0xfffffffe, 0x01000024, 0x00356700, 0x8900ac00, 0x00bd00ef};`
- `unsigned lista[SIZE]={0x0 , 0x10204080, 0x3590ac06, 0x70b0d0e0, 0xffffffff, 0x12345678, 0x9abcdef0, 0xcafebeef};`

Los resultados deberían ser 4, 156, 116, respectivamente. Notar que la lista se declara sin signo para que los desplazamientos (que previsiblemente tendremos que utilizar) no dupliquen ningún bit de signo.

Para poder comparar los tiempos de ejecución de distintos programas (de distintos usuarios) en el laboratorio (con los mismos ordenadores), necesitaremos acordar algún ejemplo de tamaño mayor, como por ejemplo SIZE=2^{20} elementos, inicializados en secuencia desde 0 hasta SIZE-1. Calcular qué peso Hamming tiene ese ejemplo (en función de SIZE) y modificar la fórmula del programa `suma_09` acordemente. Para ello podemos (en realidad debemos, si es que queremos calcularlo con una fórmula) aprovechar razonamientos específicos para el array en cuestión. Pista: ¿se puede aplicar algún razonamiento al bit 0 de todos los elementos? ¿Y al bit 19? ¿Y a los bits intermedios?

Realizar una **primera** y **segunda** versiones C como las vistas en clase (Tema 2.2, tr.43 y 38), recorriendo el array con un bucle `for`, y recorriendo los bits con bucle `for` (1ª versión, p.43) o con un bucle `while` (2ª versión, p.38), aplicando en ambos máscara 0x1 y desplazamiento a la derecha (p.38), para ir extrayendo y acumulando los bits (ver [1]). Compararíamos los tiempos para comprobar que a veces se pueden obtener buenas ganancias pensando bien las cosas en C, sin necesidad de usar ASM.

Notar que la variable `result` puede continuar usándose para seguir sumando los bits de otro elemento. Notar que preferimos llamar "1ª versión" a la del bucle `for` (tr.43), que previsiblemente tendrá peores prestaciones que el bucle `while` (incluso usando el mismo desplazamiento a derecha), porque debe iterar siempre `8*sizeof(int)` veces independientemente del nº de bits activados.

Realizar una **tercera** versión traduciendo el bucle interno `while` por un tramo de unas 5-7 líneas ensamblador que incluyan la instrucción ADC que ya utilizamos en la práctica anterior. La idea consiste en que como el bit desplazado acaba en el acarreo (consultar el manual de SHR), de ahí mismo lo podemos sumar y nos ahorramos aplicar la máscara. También puede ser útil notar que los saltos condicionales (como JZ) no alteran el flag CF, aunque ADC sí que afecta el flag ZF. En principio, debería suponer alguna mejora sobre la 2ª versión. El resultado podría sorprendernos. Por facilitar el desarrollo de este primer ejemplo, propuesto como ejercicio preparatorio, indicamos unas posibles restricciones:

```
    for (i=0; i<len; i++) {
      x = array[i];
      asm("\n"
"ini3:                \n\t"
       "shr %[x]      \n\t"          // desplazar afecta CF y ZF
       ...
       : [r]"+r" (result)            // e/s:     inicialmente 0, salida valor final
       : [x] "r" (x)       );        // entrada: valor elemento
    }
```

Implementar como **cuarta** versión la solución que aparece en el libro de clase [1], problema 3.49, resuelto en la página 364 (lenguaje C). Viene resuelto para 64bits (y un único elemento), bastaría con adaptarlo a 32bits (y un array completo). El código se basa en aplicar sucesivamente (8 veces) la máscara 0x0101… a cada elemento, para ir acumulando los bits de cada byte en una nueva variable `val` (no podemos acumular los bits de uno en uno en `result` como antes) y sumar en árbol los 4B. Esta cuarta versión nos demostraría, caso de ser mejor, lo difícil que es ganar a un programa C bien pensado.

Para una **quinta** versión, podemos buscar con Google qué otros métodos han usado algunos entusiastas para calcular el *popcount*, e implementar alguno de ellos (ver [5], instrucción SSSE3 PSHUFB). Compararíamos con el crono de la versión anterior para ver cuánto se gana por pasar del repertorio normal a SSSE3. La Figura 13 y los párrafos tras ella se dedican a explicar el método [5].

Una **sexta** versión consistiría en sustituir todo el bucle interno `while` por la instrucción SSE4 popcount. Compararíamos con el crono de la versión 5 para ver cuánto se gana por pasar del repertorio SSSE3 a SSE4 (y a lo mejor nos volveríamos a sorprender). Atendiendo a que esta versión no se podría ejecutar en el laboratorio, o en un portátil que no tenga SSE4, se deja tan sólo como sugerencia.

Para los entusiastas que siempre desean algo más, sugerimos una **séptima** y última versión para mejorar prestaciones, consistente en realizar dos lecturas y dos *popcount*. En modo de 32bits no podemos usar el *popcount* de 64bits, siendo ésto lo más parecido que se puede conseguir. Ambos ejemplos se ofrecen resueltos, aunque no se puedan ejecutar en el laboratorio.

```
// Versión SSE4.2 (popcount)
int popcount6(unsigned* array, int len)
{
    int i;
    unsigned x;
    int val, result=0;

    for (i=0; i<len; i++)
    {
      x = array[i];
      asm("popcnt %[x], %[val]"
       : [val] "=r" (val)
       :   [x]  "r" (x)
      );
      result += val;
    }
    return result;
}
```

```
// popcount 64bit p/mejorar prestaciones
int popcount7(unsigned* array, int len){
    int i;
    unsigned x1,x2;
    int val,result=0;
    if (len & 0x1)
      printf("leer 64b y len impar?\n");
    for (i=0; i<len; i+=2)    {
      x1 = array[i]; x2 = array[i+1];
      asm("popcnt %[x1], %[val] \n\t"
          "popcnt %[x2], %%edi  \n\t"
          "add    %%edi, %[val] \n\t"
        : [val] "=r" (val)
        :  [x1]  "r" (x1),
           [x2]  "r" (x2)
        : "edi");
      result += val;    }
    return result;    }
```

```
// Versión SSSE3 (pshufb) web http:/wm.ite.pl/articles/sse-popcount.html
int popcount5(unsigned* array, int len)
{
    int i;
    int val, result=0;
    int SSE_mask[] = {0x0f0f0f0f, 0x0f0f0f0f, 0x0f0f0f0f, 0x0f0f0f0f};
    int SSE_LUTb[] = {0x02010100, 0x03020201, 0x03020201, 0x04030302};
                    //    3 2 1 0     7 6 5 4    1110 9 8    15141312
    if (len & 0x3) printf("leyendo 128b pero len no múltiplo de 4?\n");
    for (i=0; i<len; i+=4)
    {
    asm("movdqu    %[x], %%     \n\t"
        "movdqa  %%xmm0, %%     \n\t"  // dos copias de x
        "movdqu    %[m], %%     \n\t"  // máscara
        "psrlw      $4 , %%     \n\t"
        "pand    %%xmm6, %%xmm0 \n\t"  //; xmm0 – nibbles inferiores
        "pand    %%xmm6, %%xmm1 \n\t"  //; xmm1 – nibbles superiores

        "movdqu    %[l], %%     \n\t"  //; ...como pshufb sobrescribe LUT
        "movdqa  %%xmm2, %%     \n\t"  //; ...queremos 2 copias
        "pshufb  %%xmm0, %%xmm2 \n\t"  //; xmm2 = vector popcount inferiores
        "pshufb  %%xmm1, %%xmm3 \n\t"  //; xmm3 = vector popcount superiores

        "paddb   %%    , %%xmm3 \n\t"  //; xmm3 – vector popcount bytes
        "pxor    %%    , %%xmm0 \n\t"  //; xmm0 =  0,0,0,0
        "psadbw  %%    , %%xmm3 \n\t"  //; xmm3 = [pcnt bytes0..7|pcnt bytes8..15]
        "movhlps %%    , %%xmm0 \n\t"  //; xmm0 = [       0      |pcnt bytes0..7 ]
        "paddd   %%    , %%xmm0 \n\t"  //; xmm0 = [    no usado  |pcnt bytes0..15]
        "movd    %%xmm0, %[val] \n\t"
```

```
        : [val]"=r" (val)
        :  [x]  "m" (array[i]),
           [m]  "m" (SSE_mask[0]),
           [l]  "m" (SSE_LUTb[0])
      );
         result +=  val;
    }
    return result;
}
```

Figura 13: popcount5: función para cálculo SSSE3 del peso Hamming (algunos registros XMM omitidos)

Para comprender el método SSSE3 propuesto en la web [5] conviene consultar el dibujo que acompaña a la página de manual de PSHUFB, la operación de ***baraje*** más corta del repertorio SSSE3. Los registros XMM (XMM0-XMM7) son de 128bits, y están pensados para almacenar en paralelo varios elementos, por ejemplo 4 enteros de 32bits (4ints x 2^5 bits/int = 2^7 bits = 128bits), 8 shorts, o 16 chars (2^4 x 2^3). La operación de ***baraje*** permite "barajar" esos elementos (como si fueran cartas de una baraja), indicando en un primer argumento el baraje deseado (en cada posición se indica el nº del dato deseado en esa posición) y en un segundo argumento los datos a barajar. Es *fundamental* advertir que en el baraje no se indica a qué posición va cada elemento (podríamos equivocarnos y dejar huecos), sino qué elemento termina en esa posición. Por fijar conceptos, la instrucción `pshufb %xmm1, %xmm2` baraja los 16 bytes de XMM2, colocando el byte i (i=0..15) en todos los bytes de XMM1 donde ponga i. Esto nos permite repetir elementos y que otros se queden fuera del resultado, lo cual puede parecer anti-intuitivo y poco relacionado con barajas de cartas. Notar también que los datos de baraje (XMM2) son sobrescritos. Conviene re-leer este párrafo junto con el dibujo del manual hasta comprender la operación de baraje.

La idea para acelerar el cálculo del *popcount* consiste en pre-calcular cuántos bits tiene activados cada número (hasta un límite dado, por ejemplo de 8 bits: 0 tiene 0bits, 1 y 2 tienen 1bit, 3 tiene 2bits… hasta 255, que tiene 8 bits activados), y usar el propio número como índice en una tabla (más o menos grande según el límite impuesto) en donde se almacenan esos resultados pre-calculados. El *popcount* de un elemento `x=array[i]` (supongamos `x`=255) es entonces `Tabla[x]` (=8). A este tipo de tabla, donde el dato disponible indexa el resultado deseado, se les suele llamar *Tabla de Consulta* (*Look-Up Table, LUT*). Por ejemplo, una paleta de colores indexados es una LUT, porque el código del color se usará como índice.

Siguiendo con el ejemplo `Tabla[array[i]]`, se tarda menos en acceder al elemento 255 de la tabla (obteniendo resultado=8bits) que hacer 8 desplazamientos, máscaras y acumulaciones. El inconveniente es que una tabla tan grande no cabe en un registro XMM. Pero si la limitamos a elementos de 4bits (medio byte, un *nibble*), sí que podemos almacenarla en un registro XMM, en donde caben 16B. De hecho nos sobra más de la mitad de cada byte, porque la LUT sólo necesita 16 elementos de 3bits: 16 porque calcularemos *popcount* de 4bits, y 3 porque el máximo son 4bits activados (0b100). Pero en SSSE3 no existe operación de baraje con 32 nibbles. La operación de baraje más corta opera sobre 16B, y nosotros aprovecharemos sólo la mitad de cada byte.

Se puede recorrer por tanto el array de 4 en 4 elementos, cargando 4 enteros en un registro XMM de 128bits (16B), repartiendo sus nibbles entre dos registros XMM (para que todos los índices salgan entre 0..15), barajando con la tabla pre-calculada (LUT) para obtener cuántos bits hay activados en cada nibble, y sumando todos esos números. La máscara y tabla se pueden consultar en la Figura 13.

Explicado paso a paso, el tramo ASM carga 4 enteros en un registro XMM y saca copia en otro XMM. Carga una máscara para quedarse con nibbles inferiores. Desplaza 4b una de las copias, de manera que al aplicar la máscara a ambas copias, resulten separados los nibbles inferiores y superiores en su correspondiente registro XMM. Se cargan entonces dos copias de la LUT y se barajan usando como índices los nibbles, obteniendo los popcount respectivos, como se explicó anteriormente.

El último tramo sirve para acumular todos esos popcount en `val`. PADDB es una suma de bytes, que se usa para reunir las cuentas de nibbles inferiores y superiores. Sumar horizontalmente esas cuentas es más complicado, debiéndose usar PSADBW (instrucción pensada para sumar valores absolutos de diferencias), que produce 2 resultados de 16b, uno en la parte menos significativa y otro en el centro del registro XMM. MOVHLPS sirve para llevar el resultado central a la parte inferior de otro registro XMM, y PADDD sirve para sumar ambos. El resultado final se puede mover a un registro de 32b con MOVD.

Notar que casi todas las restricciones se han indicado en memoria, encargándonos nosotros del movimiento explícito a registros (con MOVDQU, para evitar problemas si los arrays resultan no estar alineados a 16B). De esta forma el tramo ASM es virtualmente idéntico al de la web [5]. Se puede usar MOVDQA para mover entre registros XMM. Notar por último que el array se recorre de 4 en 4 elementos, y que dicho recorrido y la acumulación son las únicas tareas que se realizan en lenguaje C. Sólo la restricción para `val` se ha indicado en registro de 32b, para optimizar su suma con `result`. El movimiento de los 32b inferiores de un registro XMM a uno de 32b se puede realizar con MOVD.

Mediciones: cronometrar las distintas versiones con –O0, –O1 y –O2

Como también nos interesa saber cómo mejora gcc según el nivel de optimización (`-O0`, `-O1`, `-O2`), repetiremos 10 mediciones de tiempo para esos 3 niveles. Se trata por tanto de recompilar 3 veces, repetir 10 mediciones, y organizar los resultados en una gráfica de paquete ofimático (Calc o Excel), mostrando los promedios de cada versión (1ª - 5ª) para cada nivel de optimización (0 - 2), tal vez con un gráfico de barras con abscisas bidimensionales versión-optimización (Excel lo denomina *"columnas 3D"*). Conviene que cambie el color de las columnas con la versión de la función, no con la optimización.

En principio se esperaría que cada versión fuera progresivamente mejor, y dentro de cada una, se mejorara con el nivel de optimización. Si alguna versión no siguiera esta tendencia, convendría probar con otro modelo de CPU para ver si es una característica propia del modelo usado, y si no lo es, se debería consultar el código ensamblador generado para intentar explicar dicho comportamiento.

Recomendaciones

Recordar que siempre se debe comprobar que el resultado es correcto. Una optimización que produce un resultado distinto sólo tiene tres explicaciones: o está mal el programa optimizado, o está mal el original, o están mal ambos.

Se puede usar compilación condicional para facilitar tanto la comprobación de los ejemplos pequeños que hemos sugerido, como la realización de las mediciones y su incorporación a una hoja Calc. Considerar el siguiente esquema: sólo si no se activa TEST se define e inicializa normalmente el array; si se activa, se define un array más corto y no se inicializa en el programa principal.

```
#define TEST          0
#define COPY_PASTE_CALC       1

#if ! TEST
  #define NBITS 20
  #define SIZE (1<<NBITS)     // tamaño suficiente para tiempo apreciable
  unsigned lista[SIZE];
  #define RESULT (...)        // fórmula
#else
/* ------------------------------------------------------------------- */
  #define SIZE 4
  unsigned lista[SIZE]={0x80000000, 0x00100000, 0x00000800, 0x00000001};
                    // 1 ^       + 1   ^     + 1      ^  + 1        ^ = 4
  #define RESULT 4
/* ------------------------------------------------------------------- */
#endif
...
int main()
{
#if ! TEST
    int i;                    // inicializar array
    for (i=0; i<SIZE; i++)
       lista[i]=i;
#endif

    crono(popcount1, "popcount1 (lenguaje C -       for)");
    ...
#if ! COPY_PASTE_CALC
    printf("calculado = %d\n", RESULT);
#endif
    exit(0);
}
```

Figura 14: uso de compilación condicional para facilitar la comprobación de ejemplos pequeños

De la misma forma, en la función `crono()` de la Figura 12 se puede programar un `printf()` alternativo para cuando estemos haciendo mediciones de tiempo con intención de incorporarlas a una hoja Calc, uno que sólo imprima el tiempo, sin mensajes adicionales, que funcionaría cuando no se active el símbolo COPY_PASTE_CALC. Podríamos entonces lanzar la ejecución de las 10 mediciones con un simple comando Shell:

```
for (( i=0 ; i<11; i++ )); do echo $i ; ./popcount; done | pr -11 -l 20 -w 80
```

En realidad ese comando lanza 11 ejecuciones, por si la primera (o alguna) sale claramente peor que el resto, y pagina los 55 números (5 versiones x 11 mediciones) en 11 columnas para poder hacer *copy-paste* fácilmente a la hoja Calc. Los comandos para recompilar y lanzar la medición se podrían anotar en la propia hoja Calc como recordatorio para cuando se desee repetir el experimento.

En el Apéndice 1 se recuerdan algunas preguntas de autocomprobación.

4.4 Calcular la suma de paridades de una lista de enteros sin signo

Utilizar el programa `suma_09` de la Figura 12 como esqueleto para cronometrar diversas versiones de una función que sume las paridades de los elementos de una lista de N números, calculadas como el XOR (lateral) de los bits de cada elemento. Notar que la suma puede llegar a ser N, si todos tienen paridad impar (y producen XOR lateral 1). Concluir que basta calcular la suma en un entero, para cualquier valor práctico de N.

Para tener alguna posibilidad de detectar errores en nuestro código, lo comprobaremos con algunos ejemplos sencillos como los sugeridos anteriormente:

- `unsigned lista[SIZE]={0x80000000, 0x00100000, 0x00000800, 0x00000001};`
- `unsigned lista[SIZE]={0x7fffffff, 0xfeffffff, 0xfffff7ff, 0xfffffffe,`
  `0x01000024, 0x00356700, 0x8900ac00, 0x00bd00ef};`
- `unsigned lista[SIZE]={0x0 , 0x10204080, 0x3590ac06, 0x70b0d0e0,`
  `0xffffffff, 0x12345678, 0x9abcdef0, 0xcafebeef};`

Los resultados deberían ser 4, 8, 2, respectivamente. Notar que la lista se declara sin signo para que los desplazamientos (que previsiblemente tendremos que utilizar) no dupliquen ningún bit de signo.

Para poder comparar los tiempos de ejecución de distintos programas (de distintos usuarios) en el laboratorio (con los mismos ordenadores), necesitaremos acordar algún ejemplo de tamaño mayor, como por ejemplo SIZE=2^{20} elementos, inicializados en secuencia desde 0 hasta SIZE-1. Calcular qué suma de paridades tiene ese ejemplo (en función de SIZE) y modificar la fórmula del programa `suma_09` acordemente. Para ello podemos (en realidad debemos, si es que queremos calcularlo con una fórmula) aprovechar razonamientos específicos para el array en cuestión. Pista: ¿se puede aplicar algún razonamiento a los dos primeros elementos? ¿Y a los siguientes 2? ¿Y a los siguientes 4?

Realizar una **primera** y **segunda** versiones C como las vistas en clase para *popcount*, recorriendo el array con un bucle `for`, y recorriendo los bits con bucle `for` (1ª versión) o con un bucle `while` (2ª versión), aplicando en ambos máscara 0x1 y desplazamiento a la derecha para ir extrayendo y acumulando los bits. Vamos a necesitar otra variable auxiliar (como `val` en la versión `popcount4`) para acumular lateralmente los bits con XOR (^=) en lugar de con suma normal (+=), y esa suma acumularla normalmente (+=) con `result`. Compararíamos los tiempos para comprobar que a veces se pueden obtener buenas ganancias pensando bien las cosas en C, sin necesidad de usar ASM.

Implementar como **tercera** versión la solución que aparece en el libro de clase [1], problema 3.22, resuelto en la página 352 (lenguaje C), adaptándola para array completo, en lugar de un solo elemento. La segunda versión no estaba tan bien pensada como nos imaginábamos: la máscara se puede aplicar al acumular con `result`, ahorrándose todas las máscaras del bucle `while`. Cuando realicemos las mediciones de tiempo comprobaremos si esta mejora es más o menos importante con los distintos niveles de optimización.

Realizar una **cuarta** versión traduciendo el bucle interno `while` por un tramo de unas 4-5 líneas ensamblador que incluyan la instrucción XOR (y SHR, que ya utilizamos en el ejemplo anterior). Notar que SHR afecta al flag ZF, pudiéndose hacer una traducción casi literal del código C de la 3ª versión, incluyendo la máscara final con 0x1. En principio, debería suponer alguna mejora sobre la 3ª versión.

Por facilitar también el desarrollo de este ejemplo, indicamos unas posibles restricciones:

```
    for (i=0; i<len; i++) {
      x = array[i];
      val = 0;
      asm("\n"
"ini3:                  \n\t"
       "xor ...         \n\t"          // desplazar afecta ZF
       ...
       : [v]"+r" (val)                // e/s:     inicialmente 0, salida valor final
       : [x] "r" (x)                  // entrada: valor elemento
      );
      result += val;
    }
```

Para una **quinta** versión, podemos recuperar la idea de sumar en árbol usada en `popcount4` (Libro de clase, Problema 3.49, p.364). La idea es someter al elemento del array a XOR y desplazamientos sucesivos cada vez a mitad de distancia (16, 8, 4, 2, 1) hasta que finalmente se hace sencillamente `x^=x>>1`. En lugar de hacerlo "a mano" (muy poco elegante, 5 líneas de código idénticas cambiando sólo la distancia de desplazamiento), se puede programar un bucle `for (j=…)` en el cual la distancia vaya cambiando, y el cuerpo del bucle sería `x^=x>>j`. De nuevo, se puede aplicar la máscara al valor final antes de acumular con `result`. Razonar por qué funciona (en qué propiedades de XOR se basa) este método.

Realizar una **sexta** versión traduciendo el bucle interno `for` por un tramo de unas 6 líneas ensamblador que incluyan las instrucciones XOR y SHR ya conocidas, y las instrucciones SETcc y MOVZx (también estudiadas en clase). La ventaja a explotar en este caso es que XOR afecta al flag PF señalando la paridad par de los 8 bits inferiores (ver libro de clase, p.300, o manual de Intel, vol.1, sección 3.4.3.1, p.3-21), pudiendo obtener el resultado a partir de PF (mediante SETcc, consultar el manual de Intel para escoger el mnemotécnico requerido) tras llegar a 8bits. En este caso no consideramos poco elegante realizar "a mano" los dos desplazamientos requeridos (16 y 8, sólamente), así que la traducción C→ASM será un poco "libre". Compararíamos con el crono de la versión 5ª para ver la ganancia por usar ASM, cuando existen instrucciones o características que gcc no sabe aprovechar.

En principio recomendaríamos las siguientes restricciones para poder operar con facilidad en 16 y 8 bits

```
      asm(
       "mov   %[x], %%edx    \n\t "  // sacar copia para XOR. Controlar el registro...
       ...                           // (EDX) nos permite usar nombres registros 8bits
       "movzx %%dl,  %[x]    \n\t"   // devolver en 32bits
       : [x]"+r" (x)                 // e/s: entrada valor elemento, salida paridad
       :
       : "edx"                       // clobber
      );
```

Mediciones y recomendaciones

Se hacen los mismos comentarios que para el problema anterior: repetir 10 mediciones para los 3 niveles de optimización, y presentar los resultados en *"columnas 3D"* de Calc o Excel, mostrando los promedios de cada versión (1ª -6ª) para cada nivel de optimización (0 - 2). En principio se esperaría que cada versión fuera progresivamente mejor, y dentro de cada una, se mejorara con el nivel de optimización. Si alguna versión no siguiera esta tendencia, intentar explicar dicho comportamiento.

Recordar que siempre se debe comprobar que el resultado es correcto. Como mínimo se debe comprobar que todas las versiones dan el resultado correcto para los ejemplos pequeños y el ejemplo grande propuestos.

Recordar que se puede usar compilación condicional para facilitar tanto la comprobación de los ejemplos como la realización de las mediciones y su incorporación a una hoja Calc. Seguramente convendría anotar en la propia hoja Calc el comando Shell usado para lanzar la ejecución de las 10 mediciones. También convendría anotar el modelo de CPU donde se hizo la medición.

En el Apéndice 1 se recuerdan algunas preguntas de autocomprobación.

5 Entrega del trabajo desarrollado

Los distintos profesores de teoría y prácticas acordarán las normas de entrega para cada grupo, incluyendo qué se ha de entregar, cómo, dónde y cuándo. Por ejemplo, puede que en un grupo se deba entregar en un documento PDF las respuestas a las preguntas de autocomprobación, los listados de los programas realizados (`parity.c`, `popcount.c`), y las gráficas de las mediciones de tiempo, subiéndolo al SWAD hasta 3 días después de la última sesión de prácticas dedicada a esta práctica, con penalización creciente por entrega tardía hasta 1 semana posterior.

Puede que en otro grupo se pueda trabajar y entregar por parejas, pero que el profesor de prácticas visite cada puesto al final de cada sesión comprobando si ambos estudiantes saben responder a las preguntas, programar en ensamblador en-línea y utilizar las herramientas, permitiendo que se suba al SWAD el trabajo en caso afirmativo.

Los profesores de teoría y prácticas de cada grupo acordarán cómo entregará ese grupo el trabajo desarrollado.

6 Bibliografía

[1] Apuntes y presentaciones de clase, y particularmente
Programación Máquina II: Aritmética y Control
sección “Bucles”, p.38 y siguientes
sección “Códigos de condición”, instrucciones `test/setcc`, p.22-25
Libro CS:APP, Problema 3.49, p.364

[2] Manuales de Intel sobre IA-32 e Intel64, en concreto el volumen 2: “Instruction Set Reference”
http://www.intel.com/content/dam/doc/manual/64-ia-32-architectures-software-developer-vol-2a-2b-instruction-set-a-z-manual.pdf

[3] Wikipedia, convenciones de llamada http://en.wikipedia.org/wiki/Calling_convention
X86 calling conventions http://en.wikipedia.org/wiki/X86_calling_conventions
WikiBook http://en.wikibooks.org/wiki/X86_Disassembly/Calling_Conventions

[4] Wikipedia, extensiones x86 MMX/SSE: http://en.wikipedia.org/wiki/X86#Extensions
MMX http://en.wikipedia.org/wiki/X86#MMX
SSE, SSE2, SSE3, SSSE3, SSE4 http://en.wikipedia.org/wiki/X86#SSE

[5] Código SSSE3 para fast popcount http://0x80.pl/articles/sse-popcount.html
Copia rescatada de http://web.archive.org/web/20100701222327/http://wm.ite.pl/articles/sse-popcount.html

[6] GAS manual http://sourceware.org/binutils/docs/as/index.html
9.13: 80386 depend.features http://sourceware.org/binutils/docs/as/i386_002dDependent.html

[7] GCC manual v.4.4 (la del laboratorio) http://gcc.gnu.org/onlinedocs/gcc-4.4.6/gcc/
5: Extensions to C Language http://gcc.gnu.org/onlinedocs/gcc-4.4.6/gcc/index.html#toc_C-Extensions
5.33: Variable attributes http://gcc.gnu.org/onlinedocs/gcc-4.4.6/gcc/Variable-Attributes.html
5.37: Assembler with C operands http://gcc.gnu.org/onlinedocs/gcc-4.4.6/gcc/Extended-Asm.html
5.38: Constraints http://gcc.gnu.org/onlinedocs/gcc-4.4.6/gcc/Constraints.html#Constraints

[8] GCC Inline Assembly HOWTO http://www.ibiblio.org/gferg/ldp/GCC-Inline-Assembly-HOWTO.html
6: More about constraints http://www.ibiblio.org/gferg/ldp/GCC-Inline-Assembly-HOWTO.html#s6

[9] Linux Assembly HOWTO http://tldp.org/HOWTO/Assembly-HOWTO/index.html
3.1: GCC inline assembly http://tldp.org/HOWTO/Assembly-HOWTO/gcc.html
Brennan’s Guide to inline asm http://www.delorie.com/djgpp/doc/brennan/brennan_att_inline_djgpp.html
5.1: Linux calling conventions http://tldp.org/HOWTO/Assembly-HOWTO/linux.html

[10] Sourceforge tutorials http://asm.sourceforge.net/resources.html#tutorials
Using asm in Linux http://asm.sourceforge.net/articles/linasm.html#InlineASM
Inline asm x86 – IBM http://www.ibm.com/developerworks/linux/library/l-ia
Otra Brennan’s – SETI@Home http://setiathome.ssl.berkeley.edu/~korpela/djgpp_asm.html
Miyagi’s intro – texto http://asm.sourceforge.net/articles/rmiyagi-inline-asm.txt

Apéndice 1. Preguntas de Autocomprobación

Para evitar inquietudes sobre si es están comprendiendo bien los tutoriales, se proporcionan a continuación una serie de preguntas sobre los mismos, que pueden considerarse como ejercicios de autocomprobación.

Las siguientes preguntas se refieren al programa suma_01_S_cdecl de la Figura 2. Aunque sea posible responder acertadamente algunas de ellas sin necesidad de realizar la sesión de depuración (ejecutando paso a paso usando ddd), se debe recordar que el objetivo de las preguntas de autocomprobación es que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial.

	Sesión de depuración suma_01_S_cdecl
1	Se puede realizar un volcado de la pila, usando Data->Memory->Examine 8 hex words(4B) $esp, en donde se ha escogido 8 por tener margen de sobra (en línea de comandos gdb sería **x/8xw $esp**). Comprobar que coincide el volcado así obtenido con la Figura 3. *El programa principal no tiene marco de pila (EBP=0), pero el S.O. le deja algo anotado en pila. Si el 1 indicara int argc=1 y el segundo argumento fuera un array de char argv[]… ¿cómo se volcaría su valor? (Examine 1 **<qué>** bytes **<argv[0]>**) ¿Qué podría ser ese argumento?*[1] Pista: Si se desea, se puede indagar más ajustando los argumentos en **ddd** con **set args <arg1> <arg2>**
2	El volcado de pila es útil para ir viendo la pila durante la ejecución del programa, conforme va cambiando ESP. Tras llamar a **suma**, se puede realizar un volcado de memoria para comprobar que el argumento #2 es nuestra lista de 9 enteros, usando Data->Memory->Examine **<cuántos>** hex words(4B) **<qué>**. ¿De dónde sacamos **<cuántos>** y **<qué>**?
3	¿Por qué la función **suma** preserva ahora %ebx y no hace lo mismo con %edx?
4	¿Qué modos de direccionamiento usa la instrucción **add (%ebx,%edx,4), %eax**? ¿Cómo se llama cada componente del primer modo? El último componente se denomina escala. ¿Qué sucedería si lo eliminásemos?
5	Es posible eliminar el factor de escala y conseguir que el programa siga funcionando correctamente sin añadir instrucciones adicionales, sino simplemente modificando las que hay. ¿Cómo? (pista: dec %ecx)
6	También es posible conseguir lo mismo dejando únicamente un puntero, **add (%edx), %eax**. ¿Cómo?
7	La instrucción **jne** en el programa original se podría cambiar por alguno de entre otros tres saltos condicionales (uno de ellos es sencillamente otro mnemotécnico para el mismo código de operación) y el programa seguiría funcionando igual. ¿Cuáles son esos 3 mnemotécnicos? ¿Qué tendría que suceder para que se notaran diferencias con el original?
8	Según la Figura 3, si hubiésemos necesitado añadir una variable local **.int** (entero de 4B) a la función suma, hubiéramos restado 4 a ESP… ¿cuándo? (entre cuáles dos instrucciones). A la salida, deberíamos sumarle 4 a ESP… ¿cuándo?
9	Si hubiésemos reservado sitio para 3 variables locales **.int** (enteros de 4B), ¿qué dos instrucciones cambiarían respecto a la pregunta anterior, y en qué cambiarían? ¿Cómo se direccionaría la segunda variable local respecto al marco de pila? Por ejemplo, ¿cómo sería la instrucción ensamblador para poner esa variable a 0?
10	Volviendo a la Figura 3, cuando una función no tiene registros salvados, sino sólo variables locales, es posible eliminarlas de otra forma alternativa, más directa que sumar el tamaño a ESP. ¿Cuál? Pista: las siguientes instrucciones serían recuperar el antiguo EBP y retornar, así que… ¿qué otra cosa se podría hacer para que POP EBP funcionara bien?

Tabla 3: preguntas de autocomprobación (suma_01_S_cdecl)

Las siguientes preguntas se refieren al programa suma_02_S_libC de la Figura 4. Aunque sea posible responder acertadamente algunas de ellas sin necesidad de realizar la sesión de depuración (ejecutando paso a paso usando ddd), se debe recordar que el objetivo de las preguntas de autocomprobación es que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial.

[1] *Preguntar a los estudiantes si han visto int main(int argc, char*argv[]). Si no, eliminar esa pregunta.*

	Sesión de depuración suma_02_S_libC
1	¿Qué error se obtiene si no se añade **–lc** al comando de enlazar? ¿Qué tipo de error es? (en tiempo de ensamblado, enlazado, ejecución…)
2	¿Qué error se obtiene si no se añade la especificación del enlazador dinámico al comando de enlazar? ¿Y si se indica como enlazador un fichero inexistente, p.ej. **<…>.so.3** en lugar de **<…>.so.2**? ¿Qué tipo de error es? (en tiempo de ensamblado, enlazado, ejecución…)
3	Proporcionar Instrucciones paso a paso para obtener un volcado como el primero de la Figura 5 (argumentos de **suma**): - en modo gráfico **ddd** (Examine <**cant**> <**fmt**> <**tam**> desde <**dir**>) y - en modo comando **gdb** (x/<**fmt**> <**addr**>)
4	En ese momento, antes de llamar a **suma**, podríamos modificar memoria con el siguiente comando gdb: **set * (int*) $esp=suma**. ¿Qué efecto tendría eso sobre nuestro programa? Para precisar la respuesta, también podemos ejecutar el comando gdb **set * (int*) ($esp+4)=2**. ¿Qué resultado se obtiene? ¿Deberían obtener todos los compañeros ese mismo resultado? ¿De qué depende que suceda eso? Dicho de otro modo… ¿qué se está sumando, al hacer esas alteraciones? (Pista: **objdump –d suma_02_S_libC** y Accesories->Calculator Hex)
5	Repetir **3** para el segundo volcado de la Figura 5 (argumentos de **printf**).
6	En ese momento, antes de llamar a **printf**, podemos modificar el puntero de pila con este comando gdb: **set $esp=$esp-4**, y modificar el tope con **set * (int*) $esp=&formato**. ¿Qué resultado se obtiene? ¿Deberían obtener todos ese mismo resultado? ¿De qué depende que suceda eso? Dicho de otro modo… ¿qué se imprime, al hacer esas alteraciones?
7	Repetir **3** para el tercer volcado de la Figura 5 (argumentos de **exit**).
8	En ese momento, justo antes de llamar a **exit**, podemos modificar el puntero de pila con el comando gdb: **set $esp=$esp+4**. ¿Qué pasa entonces? ¿En qué afecta eso a nuestro programa? ¿Deberían obtener todos ese resultado? ¿De qué depende el resultado?
9	Repetir **8** poniendo -4 en lugar de +4

Tabla 4: preguntas de autocomprobación (suma_02_S_libC)

Las siguientes preguntas se refieren al programa suma_03_SC de la Figura 6. Aunque sea posible responder acertadamente algunas de ellas sin necesidad de realizar la sesión de depuración (ejecutando paso a paso usando ddd), se debe recordar que el objetivo de las preguntas de autocomprobación es que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial.

	Sesión de depuración suma_03_SC
1	¿Qué comando **gdb** se puede usar para ver el punto de entrada? Si no conocemos ese comando… ¿qué problemas tendríamos para depurar un programa como éste? Reconocer la importancia de dominar no sólo el modo gráfico **ddd**, sino también la línea de comandos **gdb**.
2	¿Qué diferencia hay entre los comandos **Next** y **Step**? (Pista: texto de ayuda) ¿Y entre esos comandos y su versión **<…>i**? Aprovechando que por primera vez incorporamos lenguaje C, poner un breakpoint en **call suma** y probar las cuatro variantes, anotando a dónde lleva exactamente cada una de ellas, y por qué. (Pista: Machine Code Window)
3	Editar el **formato** para que sea idéntico al de suma_02 (acabado en \n), reconstruir el programa y ejecutarlo. Explicar con precisión por qué se obtiene GCC: (Ubuntu 4.4 .3-4ubuntu5) 4.4.3. (Pista: objdump -s)
4	Obtener el código ensamblador generado para suma (no con ddd->Machine Code Window, sino con gcc) y compararlo con nuestra suma_01. ¿Qué diferencias hay? Sugerencia: quitar información de depuración para simplificar el listado.
5	Probar las opciones ddd-> Data-> Display Local Variables/Display Arguments. ¿Qué significa “value optimized out”? Pista: ir avanzando en **suma** con **Stepi** hasta que desaparezca el mensaje “optimized out”. ¿Cuándo desaparece? Es posible poner un breakpoint sobre la Machine Code Window, no tiene por qué ser en la Source Window.
6	También se puede compilar el módulo C sin optimización. No hace falta re-ensamblar el módulo ASM, basta con re-enlazar el ejecutable. Comprobar si sigue saliendo el mensaje. ¿Qué direcciones tienen las variables locales **i** y **res** tras dicho cambio? Realizar un dibujo del marco de pila de **suma** sin optimización.

Tabla 5: preguntas de autocomprobación (suma_03_SC)

Las siguientes preguntas se refieren al programa suma_04_SC de la Figura 7. Se espera que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial, realizando la sesión de depuración (ejecutando paso a paso usando ddd), y respondiendo estas preguntas.

	Sesión de depuración suma_04_SC
1	Obtener el código ensamblador generado para **suma** (no con ddd->Machine Code Window, sino con gcc) y compararlo con el anterior **suma_03**. ¿Qué diferencias hay? Sugerencia: quitar información de depuración para simplificar el listado. Otra sugerencia: comparar también con el **suma.s** original de la Figura 1.
2	Una de esas diferencias nos hace pensar que nuestra versión ensamblador de **suma** no implementa exactamente un bucle **for**, y podría producir un resultado incorrecto para cierto tamaño de la lista… ¿Cuál? ¿Por qué?
3	Otras diferencias están en el manejo de pila. Explicar dichas diferencias. Los curiosos pueden buscar **__printf_chk flag** con Google.
4	Ejecutar **nm** sobre ambos objetos C/ASM y sobre el ejecutable, indicando qué significa cada letra y fijándose en los valores (direcciones) asociados con cada símbolo. Notar que las direcciones en el ejecutable son definitivas. ¿Qué símbolos carecen de dirección? ¿Cómo es posible que **_start** y **lista** tengan la misma dirección en los objetos? ¿Por qué no tienen la misma dirección en el ejecutable?
5	¿Cómo es posible que aún queden símbolos sin definir (U) en el ejecutable?
6	Ejecutar **nm** sobre los objetos y ejecutable del ejemplo anterior **suma_03**, y explicar las diferencias con **suma_04**: ¿Por qué el módulo C tiene ahora símbolos indefinidos? ¿Cuál podría ser el motivo de que los símbolos anteriormente (d) sean ahora (D)? (Pista: comparar fuentes) ¿Por qué varía el nombre del símbolo **printf**?
7	En relación con **5**, ¿por qué cambian los nombres de los símbolos **printf** y **exit** del objeto al ejecutable, tanto en **suma_03** como en **suma_04**?
8	¿Cómo se podría comprobar la afirmación de que los símbolos no resueltos se rellenan a cero? (se afirma en la sección Ejercicio 4: suma_04_SC) (Pista: objdump). Localizar los 6 símbolos indefinidos y comprobar si se rellenan a cero. ¿Hay alguno que se rellene a valor distinto de cero? Comparar el objeto con el ejecutable.

Tabla 6: preguntas de autocomprobación (suma_04_SC)

Las siguientes preguntas se refieren al programa suma_05_C de la Figura 8. Se espera que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial, realizando la sesión de depuración (ejecutando paso a paso usando ddd), y respondiendo estas preguntas.

	Sesión de depuración suma_05_C
1	Volver a probar las diferencias entre **Next/Step** y sus variantes **<…>i** aprovechando la llamada a **suma**. Poniendo un breakpoint en la primera línea de **main**, ¿qué efecto tiene cada uno de los comandos? Seguramente conviene visualizar Machine Code Window, Display->Locals/Args, y un volcado de pila, y pulsar varias veces cada comando a partir del breakpoint.
2	Pulsando una vez **Next** tras el breakpoint, identificar en el volcado de pila los argumentos (su valor se indica en el volcado Data->Display Args), y partiendo de ahí, identificar los componentes del marco de pila. Puede ser interesante utilizar Status->Backtrace (o **disas main**, en línea de comandos) para comprobar la dirección de retorno.
3	Comprobar la respuesta anterior reiniciando la ejecución y avanzando con **Stepi**. Esto nos permite comprobar dos valores del marco de pila que antes sólo podíamos suponer, basándonos en el desensamblado. ¿Cuáles?
4	Como hemos comprobado, **main** sí que tiene marco de pila (**_start** no tenía, recordar EBP=0). Recordando la primera pregunta de comprobación del guión, ¿cómo se volcarían los argumentos de main? (Pista: esta vez, el segundo argumento es char*argv[], y convendría usar Examine <n> **<qué>** bytes ***<argv>**. Recordar que se pueden ajustar los argumentos con **set args**.)
5	Con **gcc –S** (y quitando depuración) podemos consultar el código ensamblador generado por **gcc** para este programa. Nos debería sonar todo, salvo algunos detalles: Se aplica una máscara al puntero de pila. ¿Cuál, y qué efecto produce? (Pista: alineamiento). Nosotros usamos **.int** para declarar enteros y arrays. ¿Qué usa **gcc**? Nosotros usamos el contador de posiciones y aritmética de etiquetas para calcular la longitud del array. ¿Qué usa **gcc**? Nosotros hemos usado **push** para introducir argumentos en pila, aunque en transparencias en clase hemos visto otros métodos. ¿Cuál usa **gcc**?

Tabla 7: preguntas de autocomprobación (suma_05_C)

Las siguientes preguntas se refieren al programa suma_07_Casm de la Figura 10. Se ofrecen para que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial.

	Preguntas de autocomprobación: suma_07_Casm
1	Comparar el código ensamblador generado por **gcc** para el ejemplo anterior (suma_06_CS) y para éste. ¿Hay alguna diferencia?
2	No necesitamos declarar como sobrescrito ninguno de los registros usados, aunque por distintos motivos. ¿Cuántos motivos distintos hay, y a qué registros se aplica cada uno? (Notar que la sentencia **asm()** implementa la función completa).
3	Por motivos estéticos, a veces se terminan las líneas ASM con "\n" y otras con "\n\t". ¿Por qué en este caso apenas se ha usado "\t"? Explicar qué edición estética realiza la sentencia **asm()** sobre la línea ASM insertada. (Pista: hacer pruebas con más/menos líneas, con/sin "\n\t", y consultar el ensamblador generado por **gcc**).
4	Esa edición estética delata que la sentencia **asm()** está pensada inicialmente para una única línea ASM. ¿En qué se nota?

Tabla 8: preguntas de autocomprobación (suma_07_Casm)

Las siguientes preguntas se refieren al programa suma_08_Casm de la Figura 11. Se ofrecen para que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial.

	Preguntas de autocomprobación: suma_08_Casm
1	Comparar el código ensamblador generado por **gcc** para el ejemplo anterior (suma_07_Casm) y para éste. ¿Hay alguna diferencia?
2	Comparar el código generado comentando y descomentando "cc" de la lista clobber. ¿Hay alguna diferencia?
3	No necesitamos declarar ningún otro sobrescrito, pero por un motivo distinto que en el ejemplo anterior. ¿Por qué?
4	Si **res** es variable de salida, ¿por qué se le ha indicado restricción "+r", en lugar de "=r"?
5	Volver a explicar por qué en este caso se prefiere acabar la línea con "\n" en lugar de "\n\t"

Tabla 9: preguntas de autocomprobación (suma_08_Casm)

Las siguientes preguntas se refieren al programa suma_09_Casm de la Figura 12. Se ofrecen para que cada uno pueda comprobar por sí mismo su correcta comprensión de los ejemplos del tutorial.

	Preguntas de autocomprobación: suma_09_Casm
1	Repasar el código ensamblador generado por **gcc** para las tres versiones. ¿Hay alguna diferencia?
2	En la versión 3 se ha añadido un clobber que antes no estaba (ver Figura 10). ¿Acaso no sirve para nada ese clobber? ¿No hay diferencias en el código ensamblador generado?
3	En la versión 3 se han escrito los registros con dos símbolos %, en lugar de uno (como en la Figura 10). ¿Qué pasa si se escriben como antes? ¿Por qué no pasaba eso antes?
4	¿Cuántos elementos tiene el array? ¿Cuánta memoria ocupa? ¿Cuánto vale la suma? ¿Qué fórmula se usa para calcular una suma como esa? ¿Cómo se llaman ese tipo de sumas?
5	El código C imprime un mensaje diciendo N*(N+1)/2=, pero luego calcula (SIZE-1)*(SIZE/2). ¿Cuál es la fórmula correcta?
6	Esa línea viene comentada con /* OF */. ¿Qué puede significar ese comentario? ¿Qué se puede decir acerca de la forma de escribir esa fórmula? Si es por "incomodidad para calcular la fórmula", ¿qué se podría haber hecho para evitar de golpe cualquier incomodidad? ¿Cómo se escribiría entonces, más cómodamente, la fórmula, y toda la instrucción **printf**?
7	En la función crono… ¿cómo se lee el tipo del primer argumento? ¿Qué formato **printf** se usa para imprimir el segundo? ¿Por qué se pasa por referencia el primer argumento de **gettimeofday**? ¿Por qué se pone a NULL el segundo? ¿Por qué se multiplica por 1E6 una de las restas, y la otra no? ¿Por qué el primer formato **printf** acaba con \t, en lugar de con \n? ¿Qué significa el formato %9ld usado en el segundo **printf**, por qué no se usa %9d, o sencillamente %d?
8	¿Hay alguna esperanza de ganar a **gcc** haciendo el tipo de cosas que venimos haciendo con **suma**? (pregunta retórica)

Tabla 10: preguntas de autocomprobación (suma_09_Casm)

Las siguientes preguntas se refieren al programa *popcount* de la Sección 4.3.

	Cuestiones sobre popcount.c
1	Dar una respuesta precisa a la primera pregunta (primer párrafo) de la Sección 4.3: en el peor caso, cuando todos los elementos tienen todos los bits activados… ¿cómo de grande puede ser N sin que haya *overflow*, si acumulamos la suma de bits en un **int**? ¿Y si se acumulara en un **unsigned**?
2	Diseñar la fórmula sugerida en el cuarto párrafo. ¿Cómo se ha razonado ese cálculo?
3	¿Por qué necesitaremos declarar la lista de enteros como **unsigned**? (comentado en el tercer párrafo) ¿Qué problema habría si se declarara como int? ¿Notaríamos en nuestro programa la diferencia? En caso negativo… ¿qué tendría que suceder para notar la diferencia?
4	En la 3ª versión (ASM) se han escogido restricciones en registros, "+r" y "r". ¿Cómo afectaría a las prestaciones que la primera restricción y/o la segunda fueran memoria "+m"/"m"? Comprobarlo con –O2, cambiando primero una de ellas, luego otra, luego ambas y midiendo 10 tiempos. Si se ha usado la primera instrucción ASM sugerida, también surge un error. ¿Cuál? ¿Por qué?
5	Si las restricciones a registro pueden ser mucho mejores que las restricciones a memoria… ¿Por qué entonces usamos sólo una restricción a registro en la versión 5ª, y las demás a memoria?
6	Realizar un dibujo de cómo funciona una iteración del algoritmo SSSE3 (5ª versión), con valores de elemento que causen que se use toda la tabla LUT, preferiblemente no en orden (porque entonces no quedaría clara la operación de baraje).
7	La versión 3 probablemente producirá resultados extraños, porque no sea mejor que la anterior (versión 2, incluso usando restricciones a registros) y/o porque tarde lo mismo independientemente del nivel de optimización. Intentar buscar explicación a ambas características, comparando los códigos ASM generados.
8	Realizar dos gráficas Calc o Excel del tipo "columnas 3D", una mostrando todos los resultados y otra mostrando la mejor versión C y las versiones ASM que le superan. ¿Qué ha tenido más impacto, mejorar la programación C o usar ASM?

Tabla 11: preguntas de autocomprobación (popcount.c)

Las siguientes preguntas se refieren al programa *parity* de la Sección 4.4.

	Cuestiones sobre parity.c
1	Diseñar la fórmula sugerida en el cuarto párrafo de la sección 4.4. ¿Cómo se ha razonado ese cálculo?
2	¿Por qué necesitaremos declarar la lista de enteros como **unsigned**? (comentado en el tercer párrafo) ¿Qué problema habría si se declarara como int? ¿Notaríamos en nuestro programa la diferencia? En caso negativo… ¿qué tendría que suceder para notar la diferencia?
3	En la 3ª versión (aplicar máscara al final) se dejó pendiente comparar con la 2ª para ver si la mejora es tan importante. ¿Lo es? ¿Para todos los niveles de optimización? En caso de que no lo sea, comparar los códigos ASM generados para encontrar una explicación (o comentar lo extraño del caso, si los fuentes no sirven para defender la explicación) ¿Cómo afectaría a las prestaciones que la primera restricción o la segunda fueran memoria "+m"/"m"? Comprobarlo con –O2, cambiando primero una de ellas, luego otra, luego ambas y midiendo 10 tiempos. Si se ha usado la primera instrucción ASM sugerida, también surge un error. ¿Cuál? ¿Por qué?
4	La 4ª versión (paso a ASM de la 3ª) probablemente sea la versión "extraña" de este ejemplo, porque no sea mejor que la anterior (incluso usando restricciones a registros) y/o porque tarde lo mismo independientemente del nivel de optimización. Intentar buscar explicación a ambas características, comparando los códigos ASM generados.
5	En la 4ª versión (ASM) se han escogido restricciones en registros, "+r" y "r". ¿Cómo afectaría a las prestaciones que la primera restricción o la segunda fueran memoria "+m"/"m"? Comprobarlo con –O2, cambiando primero una de ellas, luego otra (no ambas), y midiendo 10 tiempos. Si se ha usado la primera instrucción ASM sugerida, probablemente no puedan ponerse ambas restricciones a memoria, porque surja un error que no puede corregirse (a diferencia de la pregunta 4 de popcount). ¿Cuál error? ¿Por qué?
6	En la 5ª versión (XOR en árbol) se pidió razonar por qué funciona ese algoritmo (x^=x>>j para j=16,8,4,2,1), y en qué propiedades de XOR se basa. Responder.
7	En la 6ª versión (aprovechar PF) se indica que ahora no nos parece poco elegante hacer la reducción en árbol "a mano". Se indica como razón que sólo hay dos desplazamientos. Comentar sobre la elegancia del código ASM final, sobre que gcc no sea capaz de generar ese tipo de código a partir del código C, y sobre que la traducción que hemos hecho ha sido algo "libre".

8	En la 6ª versión se usa en *clobber* EDX. Probar a quitarlo y recompilar con los tres niveles de optimización. ¿Pasa algo? ¿Para cuáles niveles? ¿Por qué? La explicación debe basarse en el código ASM generado.
9	Realizar dos gráficas Calc o Excel del tipo "columnas 3D", una mostrando todos los resultados y otra mostrando la mejores versiones, C y ASM. ¿Qué ha tenido más impacto, mejorar la programación C o usar ASM?

Tabla 12: preguntas de autocomprobación (parity.c)

A continuación se muestran ejemplos del tipo de hoja de cálculo deseada, en donde se anotan las mediciones (incluso repetidas, para poder corregir mediciones erróneas), el comando usado para compilar el programa, el comando usado para lanzar la medición, el modelo de CPU usada, e incluso un texto recordatorio de que se están realizando 11 mediciones por si la primera suele salir mal.

Para que los gráficos de columnas 3D resulten intuitivos, se ha procurado que cambie el color de columna con la versión, y se mantenga para los distintos niveles de optimización. También se ha procurado que al fondo aparezcan las mediciones más lentas, para que no tapen a las más rápidas. Otro detalle para facilitar la comprensión consiste en añadir un texto que describa aproximadamente lo que se hacía en cada versión, de manera que se pueda recordar de qué versión estamos hablando. El texto descriptivo no se incluye a la hora de etiquetar los ejes.

Notar que las tablas grises son otra medición, por si acaso algún número estuviera claramente mal y necesitáramos sustituirlo por otra medición correcta. La media se hace de las mediciones 1-10, excluyendo la medición 0, que estadísticamente suele salir peor que el resto. Notar también que ha sido necesario reordenar las medias (tabla roja) de forma que sea fácil generar la gráfica a partir de la tabla roja.

Se añade otra gráfica, copia de la primera, eliminando todas las versiones salvo la última de lenguaje C y las últimas ASM (que mejoran el tiempo), para apreciar mejor el factor de mejora que supone utilizar ASM.

Notar por último que se resalta el modelo de CPU usado. En esta CPU, a `popcount3` no le afecta el nivel de optimización ni supone una mejora sobre la versión C. Las versiones SSE3 y SSE4 son muy superiores.

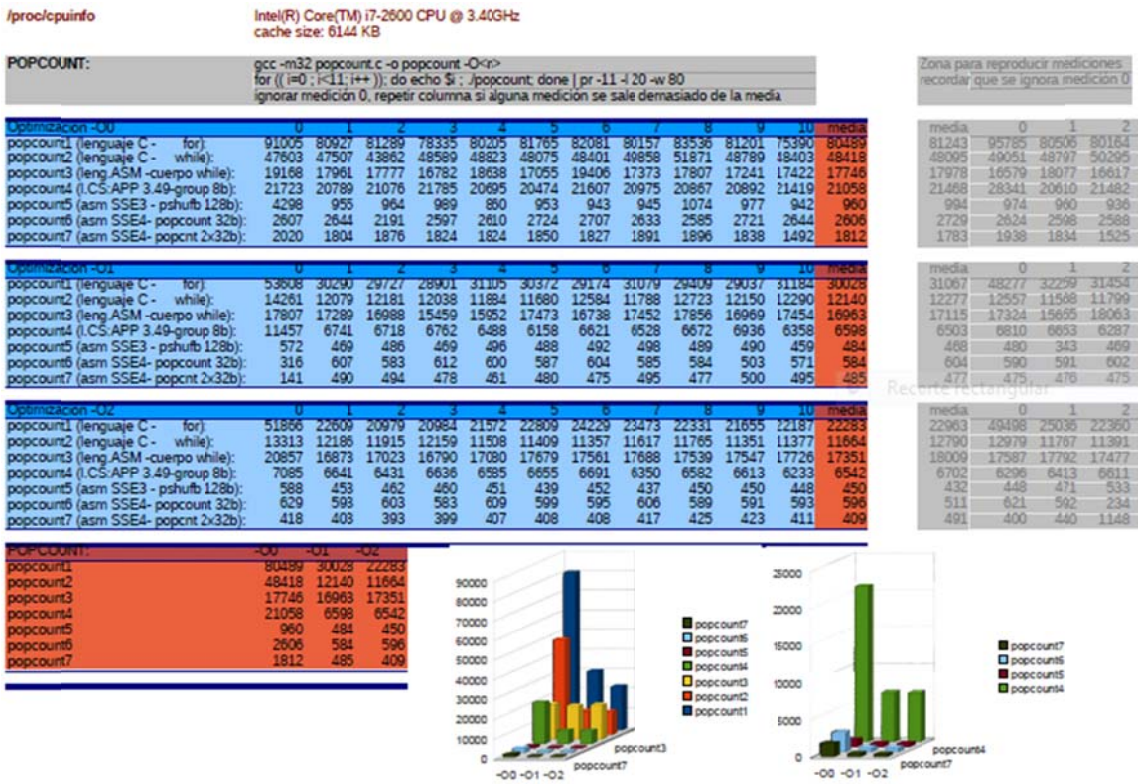

Similarmente le sucede con `parity4`, cuyas prestaciones vuelven a ser independientes del nivel de optimización ni tampoco mejora significativamente la versión C equivalente (aunque tampoco la empeora). Los tres factores de mejora importantes han sido pasar de `for` a `while` (1.77x), pasar a reducir en árbol (2.44x), y por último usar el bit PF (5.49x), quedando así cuantificada numéricamente la importancia relativa de cada mejora.

/proc/cpuinfo — Intel(R) Core(TM) i7-2600 CPU @ 3.40GHz, cache size: 6144 KB

PARITY: gcc -m32 parity.c -o parity -O<n>
for ((i=0 ; i<11; i++)); do echo $i ; ./parity; done | pr -11 -l 20 -w 80
ignorar medición 0, repetir columna si alguna medición se sale demasiado de la media

Zona para reproducir mediciones recordar que se ignora medición 0

Optimización -O0	0	1	2	3	4	5	6	7	8	9	10	media
parity1 (enguaje C - for):	106796	85856	86482	86781	85436	87493	86759	86408	85205	85780	85555	86176
parity2 (enguaje C - while):	44649	44958	44568	43671	44719	43990	44349	44545	44554	45336	44075	44477
parity3 (.CS:APP 3.22 - mask final):	37695	37546	37645	38925	37257	38657	37754	38102	37957	37723	37800	37937
parity4 (enguaje ASM- cuerpo while):	12634	13078	13104	12668	13554	12900	12478	12334	13545	13628	13008	13030
parity5 (.CS:APP 3.49 - 32b,16..1b):	14415	13549	14004	14284	14101	13762	14401	14018	14459	14146	13754	14048
parity6 (eng.ASM-cuerpo for- setnp):	3489	3380	3394	3393	3605	3376	3512	3515	3508	4023	3418	3512

media	0	1	2
85373	99365	85047	85403
45054	44567	43524	44943
37503	37578	38179	37450
12511	12058	12145	13148
14454	14680	13946	14901
3388	3202	3284	3495

Optimización -O1	0	1	2	3	4	5	6	7	8	9	10	media
parity1 (enguaje C - for):	48344	35500	30289	36238	29279	29904	30502	31295	29744	30033	32646	31543
parity2 (enguaje C - while):	17867	17237	17192	16938	16551	16773	16830	16899	17100	17403	21008	17394
parity3 (.CS:APP 3.22 - mask final):	11262	11488	11408	11570	11646	11462	12211	11278	11174	11133	12588	11596
parity4 (enguaje ASM- cuerpo while):	11583	11664	11999	11480	12150	11739	11723	12262	13064	11415	11638	11913
parity5 (.CS:APP 3.49 - 32b,16..1b):	5074	4868	4675	4910	4974	5692	6514	4909	4906	5045	4975	5147
parity6 (eng.ASM-cuerpo for- setnp):	1077	1163	1048	1052	1042	1050	1062	1026	1129	1054	1072	1070

media	0	1	2
31256	56628	32167	32725
17296	17005	17190	17254
11646	12319	11313	11029
12039	11389	11626	12224
4963	4964	4967	4940
1261	1067	1115	1040

Optimización -O2	0	1	2	3	4	5	6	7	8	9	10	media
parity1 (enguaje C - for):	51085	23824	23624	21535	20972	21320	21230	21424	24913	22026	22315	22318
parity2 (enguaje C - while):	12505	12086	12541	11771	12415	12537	13119	13200	12260	12441	13855	12623
parity3 (.CS:APP 3.22 - mask final):	11549	11506	11042	13640	12206	12107	11569	11632	11072	12298	11695	11877
parity4 (enguaje ASM- cuerpo while):	10981	11296	11712	11289	11602	12458	11369	9945	12356	11468	11556	11505
parity5 (.CS:APP 3.49 - 32b,16..1b):	5278	5187	5073	4993	5497	4771	4698	6053	5539	5131	4776	5172
parity6 (eng.ASM-cuerpo for- setnp):	973	960	954	980	980	813	965	968	1010	905	883	942

media	0	1	2
22626	38415	23545	22210
12369	13257	12893	11795
11880	11124	11302	12048
11357	11949	12868	10957
5333	4993	5030	5233
955	961	974	964

PARITY:	-O0	-O1	-O2
parity1	86176	31543	22318
parity2	44477	17394	12623
parity3	37937	11596	11877
parity4	13030	11913	11505
parity5	14048	5147	5172
parity6	3512	1070	942